



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΤΕΧΝΟΛΟΓΙΑΣ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ

ΕΡΓΑΣΤΗΡΙΟ ΣΥΣΤΗΜΑΤΩΝ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ ΚΑΙ ΜΑΘΗΣΗΣ

Βελτίωση Ανάλυσης Εικόνας με Χρήση Μοντέλων Διάχυσης: Εφαρμογές στην Ιατρική Απεικόνιση και στην Αυτόνομη Οδήγηση

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΠΑΝΑΓΙΩΤΗ ΚΡΑΝΙΑ

Επιβλέπων: Στέφανος Κόλλιας

Ομότιμος Καθηγητής Ε.Μ.Π.

Συνεπιβλέπουσα: Παρασκευή Τζούβελη

ΕΔΙΠ Ε.Μ.Π.

Αθήνα, Μάιος 2025



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΤΕΧΝΟΛΟΓΙΑΣ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ

ΕΡΓΑΣΤΗΡΙΟ ΣΥΣΤΗΜΑΤΩΝ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ ΚΑΙ ΜΑΘΗΣΗΣ

Βελτίωση Ανάλυσης Εικόνας με Χρήση Μοντέλων Διάχυσης: Εφαρμογές στην Ιατρική Απεικόνιση και στην Αυτόνομη Οδήγηση

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΠΑΝΑΓΙΩΤΗ ΚΡΑΝΙΑ

Επιβλέπων: Στέφανος Κόλλιας

Ομότιμος Καθηγητής Ε.Μ.Π.

Συνεπιβλέπουσα: Παρασκευή Τζούβελη

ΕΔΙΠ Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 5 Μαΐου 2025.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Στέφανος Κόλλιας
Ομότιμος Καθηγητής Ε.Μ.Π.

.....
Ανδρέας-Γεώργιος Σταφυλοπάτης
Ομότιμος Καθηγητής Ε.Μ.Π.

.....
Γιώργος Στάμου
Καθηγητής Ε.Μ.Π.

Αθήνα, Μάιος 2025



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΤΕΧΝΟΛΟΓΙΑΣ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ

ΕΡΓΑΣΤΗΡΙΟ ΣΥΣΤΗΜΑΤΩΝ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ ΚΑΙ ΜΑΘΗΣΗΣ

.....

Παναγιώτης Κράνιος

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright ©– Παναγιώτης Κράνιος, 2025.

All rights reserved. Με την επιφύλαξη παντός δικαιώματος.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου

στον παππού μου, Χρήστο

Περίληψη

Η παρούσα διπλωματική εργασία εξετάζει την εφαρμογή της τεχνικής της Υπερανάλυσης Εικόνας (Super-Resolution) με τη χρήση εξελιγμένων μοντέλων διάχυσης (Diffusion Models) σε δύο διαφορετικούς τομείς: την ιατρική απεικόνιση και την αυτόνομη οδήγηση. Συγκεκριμένα, χρησιμοποιήθηκαν το σύνολο δεδομένων BraTS2023, το οποίο περιλαμβάνει μαγνητικές τομογραφίες (MRIs) ασθενών και απoσκοπεί στην ανάλυση όγκων εγκεφάλου, καθώς και ένα νεοσύστατο σύνολο δεδομένων φωτεινών σηματοδοτών, το οποίο δημιουργήθηκε ειδικά για τις ανάγκες της παρούσας εργασίας, για εφαρμογές σε αυτόνομα οχήματα. Στόχος της μελέτης είναι η αξιολόγηση της αποτελεσματικότητας και των δυνατοτήτων των μοντέλων διάχυσης στον τομέα της υπερανάλυσης εικόνας.

Η προτεινόμενη προσέγγιση βασίζεται στη δυναμική των μοντέλων διάχυσης, μιας καινούργιας κατηγορίας μοντέλων μηχανικής μάθησης που αξιοποιούν την αρχιτεκτονική U-Net, με σκοπό την παραγωγή εικόνων υψηλής ανάλυσης από αντίστοιχες χαμηλής ανάλυσης. Για τη βελτιστοποίηση της απόδοσης του μοντέλου, στα δεδομένα εφαρμόστηκαν τεχνικές προεπεξεργασίας, όπως κανονικοποίηση, αλλαγή μεγέθους και τυποποίηση, ώστε να διασφαλιστεί η συνέπεια και η συμβατότητα με το μοντέλο καθώς και να αυξηθεί το μέγεθος των datasets μέσω τεχνικών επαύξησης δεδομένων (data augmentation). Η αξιολόγηση της απόδοσης των μοντέλων πραγματοποιήθηκε μέσω αντικειμενικών μετρικών ποιότητας εικόνας, όπως το CLIPQA και το MUSIQ, που επιτρέπουν την ποσοτική αποτίμηση της ποιότητας των παραγόμενων εικόνων, λαμβάνοντας υπόψη τόσο τα αντιληπτικά χαρακτηριστικά όσο και την πιστότητα της υπερ-ανάλυσης.

Τα πειραματικά αποτελέσματα καταδεικνύουν ουσιαστικές βελτιώσεις στην ανάλυση εικόνων του συνόλου BraTS2023, αποδεικνύοντας τη δυναμική των μοντέλων διάχυσης σε εφαρμογές ιατρικής απεικόνισης. Ωστόσο, το σύνολο δεδομένων φωτεινών σηματοδοτών παρουσίασε προκλήσεις, κυρίως λόγω της περιορισμένης ποικιλομορφίας και ποιότητάς του, με αποτέλεσμα οι βελτιώσεις στην ανάλυση να είναι λιγότερο εμφανείς. Συμπερασματικά, τα μοντέλα διάχυσης παρουσιάζουν πολλές προοπτικές για εργασίες υπερανάλυσης εικόνας σε ελεγχόμενα περιβάλλοντα, αλλά απαιτείται περαιτέρω έρευνα για την αντιμετώπιση ζητημάτων όπως η ποικιλομορφία των δεδομένων, η βελτιστοποίηση των μοντέλων και οι υπολογιστικές απαιτήσεις για ευρύτερες εφαρμογές.

Λέξεις Κλειδιά

Υπερανάλυση εικόνας, Μοντέλα Διάχυσης, Ανακατασκευή εικόνας, Ιατρική απεικόνιση, Αυτόματη οδήγηση, Βαθιά Μάθηση, Παραγωγικά Μοντέλα, Όραση Υπολογιστών, U-Net, Ανίχνευση Αντικειμένων, Yolo

Abstract

This thesis explores the application of image Super-Resolution using advanced Diffusion Models in two distinct domains: medical imaging and autonomous driving. Specifically, two datasets were utilized: BraTS2023, which contains magnetic resonance imaging (MRI) scans of patients for the analysis of brain tumors, and a newly established dataset of traffic lights, which was specifically created for this study to support autonomous vehicle applications. The aim of this research is to evaluate the effectiveness and potential of diffusion models in the field of super-resolution.

The proposed approach leverages the capabilities of diffusion models, a novel class of machine learning models that utilize the U-Net architecture to generate high-resolution images from their low-resolution counterparts. To optimize the model's performance, several preprocessing techniques were applied to the dataset, including normalization, resizing, and standardization, ensuring consistency and compatibility with the model while also expanding the dataset using data augmentation techniques. The performance evaluation of the models was conducted using objective image quality metrics, such as CLIPQA and MUSIQ, which provide quantitative assessments of the generated images by considering both perceptual characteristics and super-resolution fidelity.

The experimental results demonstrate significant improvements in the image resolution of the BraTS2023 dataset, confirming the potential of diffusion models in medical imaging applications. However, the traffic light dataset presented certain challenges, primarily due to its limited diversity and image quality, resulting in less noticeable improvements.

In conclusion, diffusion models exhibit strong potential for super-resolution tasks in controlled environments, where data quality and structure are well-defined. However, further research is required to address key challenges, such as dataset diversity, model optimization, and computational requirements, to enable their broader application in real-world scenarios.

Keywords

Super-Resolution, Diffusion Models, Image Reconstruction, Medical Imaging, Autonomous Driving, Deep Learning, Generative Models, Computer Vision, U-Net, Object Detection, Yolo

Ευχαριστίες

Θα ήθελα καταρχήν να ευχαριστήσω τον καθηγητή κ. Στέφανο Κόλλια για την επίβλεψη αυτής της διπλωματικής εργασίας και για την ευκαιρία που μου έδωσε να την εκπονήσω στο Εργαστήριο Συστημάτων Τεχνητής Νοημοσύνης και Μάθησης. Επίσης ευχαριστώ ιδιαίτερα την κ. Παρασκευή Τζούβελη για την καθοδήγησή της και την εξαιρετική συνεργασία που είχαμε. Τέλος θα ήθελα να ευχαριστήσω τους γονείς μου για την καθοδήγηση και την ηθική συμπαράσταση που μου προσέφεραν όλα αυτά τα χρόνια.

Αθήνα, Μάιος 2025

Παναγιώτης Κράνιας

Περιεχόμενα

Περίληψη	7
Abstract	9
Ευχαριστίες	11
I Εκτεταμένη Περίληψη στα Ελληνικά	23
1 Εισαγωγή	25
1.1 Κίνητρο	25
1.2 Σκοπός	25
1.3 Δομή	26
2 Θεωρητικό υπόβαθρο	27
2.1 Υπερανάλυση Εικόνας	27
2.2 Ανίχνευση Αντικειμένων	28
2.3 Συνελκτικά Νευρωνικά Δίκτυα	29
2.4 U-Net	31
2.5 Knowledge Distillation	32
2.6 Μοντέλα Διάχυσης	34
3 Μέθοδος και αποτελέσματα	37
3.1 Σύνολα Δεδομένων	37
3.1.1 Brats2023	37
3.1.2 Traffic Lights	39
3.2 Υπερανάλυση με το μοντέλο SinSR	45
3.2.1 Διατύπωση Προβλήματος	45
3.2.2 Αρχιτεκτονική	46
3.2.3 Εκπαίδευσης	46
3.2.4 Συναρτήσεις Απώλειας	46
3.2.5 Πλεονεκτήματα του SinSR	47
3.2.6 Μετρικές Αξιολόγησης	47
3.3 Η Διάταξή μας	47
3.4 Μετρικές	48
3.5 Αποτελέσματα	48

4 Επίλογος	57
4.1 Συμπεράσματα	57
4.2 Μελλοντικές Επεκτάσεις	57
 II English Version	 59
5 Introduction	61
5.1 Motivation	61
5.2 Scope of work	62
5.3 Structure	62
 6 Theoretical Background	 65
6.1 Image Super Resolution	65
6.2 Object Detection	67
6.3 Convolutional Neural Networks	68
6.4 U-Net	69
6.5 Vision Transformers and Swin Transformer	71
6.6 Knowledge Distillation	73
6.7 Generative Modeling for Image Super-Resolution: A Historical Perspective	74
6.7.1 Autoregressive Models	74
6.7.2 Variational Autoencoders (VAEs)	75
6.7.3 Normalizing Flows (NFs)	76
6.7.4 Generative Adversarial Networks (GANs)	76
6.7.5 Comparative Overview of Generative Models	76
6.7.6 Conclusion and the Emergence of Diffusion Models	77
6.8 Diffusion Models	78
 7 Methodology	 83
7.1 Data Sets	83
7.1.1 BraTS2023	83
7.1.2 Traffic Lights	86
7.2 Super-Resolution with SinSR	92
7.2.1 Problem Formulation	92
7.2.2 Architecture Overview	92
7.2.3 Training Strategy: Distillation from Diffusion	93
7.2.4 Loss Functions	93
7.2.5 Advantages of SinSR	94
7.2.6 Evaluation Metrics	94
7.3 Object Detection with YOLO	95
7.3.1 Introduction	95
7.3.2 Model Architecture	95
7.3.3 Training Process	96
7.3.4 Inference and Object Detection Pipeline	96

7.3.5 Evaluation Metrics	97
7.3.6 Summary and Key Takeaways	97
7.4 Layout and Integration Pipeline	97
8 Results and Evaluation	101
8.1 Evaluation Metrics	101
8.2 Comparative Evaluation of Our Pipeline	103
9 Conclusion	111
9.1 Conclusion	111
9.2 Future Extensions	111
Βιβλιογραφία	118

Κατάλογος Σχημάτων

2.1	Σύγκριση δορυφορικής εικόνας της πόλης του Παρισιού χαμηλής ανάλυσης (αριστερά) με την αντίστοιχη εικόνα υψηλής ανάλυσης (δεξιά), αναδεικνύοντας την ενισχυμένη ευκρίνεια και λεπτομέρεια που επιτυγχάνονται μέσω τεχνικών επεξεργασίας εικόνας.	28
2.2	Ανίχνευση αντικειμένων σε αστική οδό, με εντοπισμό οχημάτων, ποδηλάτων, πεζών και φωτεινού σηματοδότη μέσω αριθμημένων πλαισίων. [1]	29
2.3	Ενδεικτική αρχιτεκτονική συνελκτικού νευρωνικού δικτύου.	30
2.4	Αρχιτεκτονική U-Net: συμμετρική δομή κωδικοποιητή-αποκωδικοποιητή για σημασιολογική τμηματοποίηση.	33
2.5	Απεικόνιση της αλυσίδας Μαρκο για την προς τα εμπρός και αντίστροφη διαδικασία διάχυσης.	34
2.6	Εικονογράφηση της αντίστροφης διαδικασίας διάχυσης.	35
2.7	Διαδικασία εκπαίδευσης και δειγματοληψίας στα μοντέλα διάχυσης.	36
3.1	Μαγνητικές τομογραφίες εγκεφάλων με παρουσία όγκων διαφόρων μεγεθών.	38
3.2	Αποτελέσματα του split σε διάστημα 30 εικόνων	39
3.3	Παραδείγματα εικόνων που ανήκουν το COCO	40
3.4	Επισημασμένες εικόνες οδήγησης από το BDD100K	41
3.5	Επισημασμένες εικόνες οδήγησης από το Bosch	41
3.6	Επισημασμένες εικόνες του συνούλου δεδομένων Google Open Images	42
3.7	Παράδειγμα εικόνας με φωτεινούς σηματοδότες από το Lisa Traffic Lights dataset	42
3.8	Η αυθεντική εικόνα (στα αριστερά) μαζί με τις επαυξημένες εκδοχές της: καθρεπτισμένη εικόνα (η δεύτερη) και οι περιστροφές της κατά -90 και +90 μοίρες αντίστοιχα	44
3.9	Διαφορετική ώρα της ημέρας	44
3.10	Διαφορετικό σχήμα φαναριού	45
3.11	Διαφορετικό χρώμα	45
3.12	Αρχιτεκτονική SinSR: το μοντέλο μαθητής προβλέπει την High Resolution εικόνα από το διαχυτικό μοντέλο δασκάλου με τη βοήθεια Knowledge Distillation.	46
3.13	Η διάταξή μας: Από την ανίχνευση αντικειμένων μέσω του YOLO στη βελτίωση της ανάλυσης μέσω του SinSR.	48
3.14	Σύγκριση μαγνητικής τομογραφίας ενός πρώτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου	50

3.15	Σύγκριση μαγνητικής τομογραφίας ενός δεύτερου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου	51
3.16	Σύγκριση μαγνητικής τομογραφίας ενός τρίτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου	51
3.17	Σύγκριση μαγνητικής τομογραφίας ενός τέταρτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου	52
3.18	Σύγκριση των αποτελεσμάτων υπερ-ανάλυσης για τον πρώτο φωτεινό σηματοδότη μεταξύ του βασικού μοντέλου SinSR και του fine-tuned μοντέλου . . .	54
3.19	Σύγκριση των αποτελεσμάτων υπερ-ανάλυσης για τον δεύτερο φωτεινό σηματοδότη μεταξύ του βασικού μοντέλου SinSR και του fine-tuned μοντέλου . .	55
6.1	Comparison of a low-resolution satellite image of the city of Paris (left) with the corresponding high resolution image (right), highlighting the enhanced sharpness and detail achieved through image processing techniques. . . .	66
6.2	Comparison between original image, bicubic upscaling, and super-resolution. Super-resolution reconstructs realistic high-frequency details rather than simply enlarging existing pixels.	66
6.3	Object detection on an urban street, with vehicle, bicycle, pedestrian and traffic light detection via numbered frames. [1]	67
6.4	Indicative neural network architecture.	68
6.5	U-Net architecture: a symmetric encoder-decoder structure for semantic segmentation.	71
6.6	(a) The proposed Swin Transformer builds hierarchical feature maps by merging image patches (shown in gray) in deeper layers and has linear computation complexity to input image size due to computation of self-attention only within each local window (shown in red). It can thus serve as a general-purpose backbone for both image classification and dense recognition tasks. (b) In contrast, previous vision Transformers [2] produce feature maps of a single low resolution and have quadratic computation complexity to input image size due to computation of selfattention globally.	72
6.7	(Left) A visualization of PixelCNN, which maps a neighborhood of pixels to predict the next pixel. (Middle) Example of a masked 5x5 filter to prevent the model from accessing pixels below or strictly to the right of the current pixel during predictions. (Right) Two convolutional stacks (blue and purple) resolving the receptive field's blind spot.	75
6.8	Comparison of three generative models: GANs, VAEs, and Normalizing Flows. 77	
6.9	Markov chain representation of the forward and reverse diffusion processes. 78	
6.10	Illustration of the forward and reverse diffusion chains.	79
6.11	Training and sampling procedures in diffusion models.	81
7.1	MRI scans of brains showing tumors of various sizes.	84
7.2	Conversion of 3D MRI volumes into 2D axial slices at 30-slice intervals. . .	85
7.3	Example images from the COCO dataset.	87

7.4	Example of labeled driving scenes from the BDD100K dataset.	88
7.5	Example of labeled traffic light images from the Bosch dataset.	88
7.6	Labeled traffic light images from the Google Open Images dataset.	89
7.7	Example images of traffic lights from the LISA Traffic Light dataset.	89
7.8	Example images from the Traffic Light Detection dataset.	89
7.9	Distribution of selected traffic light images from each dataset after filtering.	90
7.10	The original traffic light patch (left), mirrored version (middle left), and its -90° and +90° rotations.	91
7.11	Visual differences in traffic lights between day and night.	91
7.12	Examples of regional differences in traffic light design.	91
7.13	Variability in traffic light color and illumination across environments. . . .	92
7.14	SinSR architecture: a student network learns to predict the HR image in a single forward pass by distilling knowledge from a multi-step diffusion teacher model.	93
7.15	YOLO running on sample artwork and natural images	95
7.16	Pipeline overview: YOLO detects objects in the input image, followed by cropping the detected region and enhancing its resolution using SinSR. . .	98
8.1	Model overview of MUSIQ	102
8.2	Illustration of CLIPQA's perceptual capabilities. (a) Image A demonstrates superior quality in terms of sharpness, brightness, and overall perceptual fidelity compared to Image B, as reflected in the radar chart. (b) CLIPQA's abstract perception distinguishes semantic attributes such as "natural," "happy," and "aesthetic" in Image A versus "scary" and "complex" tones in Image B. These examples highlight CLIPQA's ability to quantify both quality and abstract impressions using multimodal embeddings.	103
8.3	MRI comparison of a first patient between the vanilla SinSR model and the fine tuned model	105
8.4	MRI comparison of the second patient between the vanilla SinSR model and the fine tuned model	105
8.5	MRI comparison of the third patient between the vanilla SinSR model and the fine tuned model	106
8.6	MRI comparison of the fourth patient between the vanilla SinSR model and the fine tuned model	106
8.7	Comparison of super-resolution results for the first traffic light between the baseline SinSR model and the fine-tuned model	108
8.8	Comparison of super-resolution results for the second traffic light between the baseline SinSR model and the fine-tuned model	109

Κατάλογος Πινάκων

3.1	Traffic Lights Detection Datasets and Number of Images	40
3.2	Συνοπτικός Πίνακας Αποτελεσμάτων για την εκπαίδευση του μοντέλου μας με το <i>BraTS2023</i>	49
3.3	Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον πρώτο ασθενή	50
3.4	Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον δεύτερο ασθενή	51
3.5	Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον τρίτο ασθενή	52
3.6	Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον τέταρτο ασθενή	52
3.7	Συνοπτικός Πίνακας Αποτελεσμάτων για την εκπαίδευση του μοντέλου μας με το <i>Traffic Light Dataset</i>	53
3.8	Ποσοτική αξιολόγηση των αποτελεσμάτων	54
3.9	Ποσοτική αξιολόγηση των αποτελεσμάτων	55
6.1	Comparison of Generative Models for Super-Resolution Tasks	77
7.1	Traffic Light Detection Datasets and Number of Images	86
8.1	Summary Table of Results for the BraTS2023 Dataset	104
8.2	Quantitative evaluation of MRI results for the first patient	105
8.3	Quantitative evaluation of MRI results for the second patient	106
8.4	Quantitative evaluation of MRI results for the third patient	106
8.5	Quantitative evaluation of MRI results for the fourth patient	107
8.6	Performance Summary on Traffic Light Dataset	107
8.7	Quantitative evaluation of super-resolution performance for the first traffic light	108
8.8	Quantitative evaluation of super-resolution performance for the second traffic light	109

Μέρος I

Εκτεταμένη Περίληψη στα Ελληνικά

Εισαγωγή

1.1 Κίνητρο

Η τεχνολογία της Υπερανάλυσης Εικόνας (Super-Resolution) έχει αναδειχθεί σε έναν από τους πιο καινοτόμους και επιδραστικούς τομείς της όρασης υπολογιστών, καθώς επιτρέπει τη βελτίωση της ποιότητας και της ευκρίνειας εικόνων χαμηλής ανάλυσης. Αυτή η τεχνολογία έχει ευρύ φάσμα εφαρμογών σε τομείς όπως η ιατρική, η αυτόνομη οδήγηση, η ασφάλεια και η τηλεπισκόπηση, όπου η ανάγκη για υψηλής ανάλυσης εικόνες είναι καθοριστική.

Πιο συγκεκριμένα, στη βελτίωση της ευκρίνειας μαγνητικών τομογραφιών εγκεφάλου, η υψηλή ανάλυση εικόνας μπορεί να συμβάλει στη διάγνωση παθήσεων με μεγαλύτερη ακρίβεια και στην πρόωπη ανίχνευση ανωμαλιών. Αντίστοιχα, στην αυτόνομη οδήγηση, η ικανότητα των συστημάτων να επεξεργάζονται καθαρές και λεπτομερείς εικόνες βελτιώνει την απόδοση, την ασφάλεια και τη συνολική αξιοπιστία των αλγορίθμων αντίληψης του περιβάλλοντος.

Η ραγδαία ανάπτυξη των Μοντέλων Διάχυσης (Diffusion Models), τα οποία αρχικά χρησιμοποιήθηκαν κυρίως για παραγωγή εικόνων, έχει ανοίξει νέες ερευνητικές προοπτικές στην υπερανάλυση εικόνας. Η παρούσα εργασία διερευνά την ικανότητα αυτών των μοντέλων να προσφέρουν καινοτόμες λύσεις σε προκλήσεις που απαιτούν βελτίωση εικόνων χαμηλής ανάλυσης, ενισχύοντας έτσι τις εφαρμογές σε ιατρικά δεδομένα και συστήματα αυτόνομης οδήγησης.

1.2 Σκοπός

Ο σκοπός της παρούσας διπλωματικής εργασίας είναι η εφαρμογή και αξιολόγηση των δυνατοτήτων των Diffusion Models στο πεδίο του Super Resolution στους τομείς της [ιατρικής απεικόνισης](#) και των [συστημάτων αυτόματης οδήγησης](#).

Ειδικότερα, η εργασία αυτή επικεντρώνεται:

1. Στη βελτίωση της ποιότητας εικόνων από μαγνητικές τομογραφίες εγκεφάλου, με στόχο την ενίσχυση της διαγνωστικής ακρίβειας.
2. Στη βελτίωση της ποιότητας εικόνων από συστήματα ανίχνευσης στην αυτόνομη οδήγηση, ώστε να εξασφαλιστεί καλύτερη ανάλυση αντικειμένων και χαρακτηριστικών του περιβάλλοντος.

3. Στην εξερεύνηση πιθανών εφαρμογών του Super Resolution σε άλλους τομείς, αξιοποιώντας την τεχνολογία των Diffusion Models.

Με την αξιολόγηση της απόδοσης των Diffusion Models στους προαναφερθέντες τομείς, η εργασία στοχεύει να προσφέρει σημαντικά ερευνητικά ευρήματα που θα ενισχύσουν την εφαρμογή αυτής της τεχνολογίας σε πραγματικές και απαιτητικές συνθήκες.

1.3 Δομή

Στο πρώτο κεφάλαιο παρουσιάζονται το κίνητρο και ο σκοπός της έρευνας, καθώς και η γενική δομή της εργασίας.

Το δεύτερο κεφάλαιο εστιάζει στο Θεωρητικό Υπόβαθρο, όπου αναλύονται οι βασικές αρχές της Υπερανάλυσης Εικόνας (Super Resolution), οι τεχνικές ανίχνευσης αντικειμένων, καθώς και τα θεμελιώδη μοντέλα μηχανικής μάθησης που χρησιμοποιούνται στον τομέα αυτό. Ειδικότερα, γίνεται αναφορά στα Συνελκτικά Νευρωνικά Δίκτυα (CNNs), το U-Net, καθώς και στη μέθοδο (Knowledge Distillation). Ιδιαίτερη έμφαση δίνεται στα Μοντέλα Διάχυσης (Diffusion Models), τα οποία αποτελούν το κύριο αντικείμενο μελέτης της παρούσας εργασίας. Επιπλέον, γίνεται αναφορά στις μετρικές αξιολόγησης των μοντέλων.

Το τρίτο κεφάλαιο αφορά τη Μέθοδο και τα Αποτελέσματα της παρούσας εργασίας. Περιγράφονται τα σύνολα δεδομένων που χρησιμοποιήθηκαν, συμπεριλαμβανομένων των BraTS2023 και Traffic Lights, καθώς και η αρχιτεκτονική και η πειραματική διαμόρφωση του μοντέλου SinSR που εξετάζεται. Αναλύεται η διάταξη των πειραμάτων, η διαδικασία εκπαίδευσης των μοντέλων και παρουσιάζονται τα αποτελέσματα που προέκυψαν από τις πειραματικές διαδικασίες.

Τέλος, στο τέταρτο κεφάλαιο διατυπώνονται τα συμπεράσματα της εργασίας, συνοψίζοντας τα ευρήματα και την απόδοση των μοντέλων. Παράλληλα, προτείνονται μελλοντικές επεκτάσεις και βελτιώσεις για περαιτέρω έρευνα και εφαρμογή της τεχνολογίας υπερανάλυσης εικόνας σε νέα πεδία εφαρμογών.

Κεφάλαιο 2

Θεωρητικό υπόβαθρο

Το παρόν κεφάλαιο παρουσιάζει τα βασικά θεωρητικά θεμέλια που υποστηρίζουν την ανάπτυξη της προτεινόμενης μεθοδολογίας υπερανάλυσης εικόνας. Αρχικά, παρατίθεται μια επισκόπηση των τεχνικών υπερανάλυσης, με έμφαση στους στόχους, τις μεθόδους και τις εφαρμογές τους. Στη συνέχεια, εξετάζονται τα συστήματα ανίχνευσης αντικειμένων, τα οποία διαδραματίζουν καθοριστικό ρόλο στον εντοπισμό σχετικών περιοχών ενδιαφέροντος πριν από τη διαδικασία ενίσχυσης της ανάλυσης.

2.1 Υπερανάλυση Εικόνας

Η υπερανάλυση εικόνας αποτελεί μια μέθοδο της όρασης υπολογιστών η οποία αποσκοπεί στην βελτίωση της ανάλυσης μία εικόνας και επιτυγχάνεται με την ανακατασκευή μιας εικόνας υψηλής ανάλυσης από μία αντίστοιχη χαμηλής ανάλυσης. Η τεχνική αυτή είναι ζωτικής σημασίας για την ανάκτηση λεπτομεριών που έχουν χαθεί λόγω περιορισμού ανάλυσης του αισθητήρα ή εξωτερικών παραγόντων και χρησιμοποιείται σε ένα ευρύ φάσμα εφαρμογών. Μεταξύ αυτών περιλαμβάνονται η δορυφορική και εναέρια απεικόνιση [3], η επεξεργασία ιατρικών εικόνων [4],[5],[6], η υπέρυθρη απεικόνιση [7], η βελτίωση εικόνας προσώπων [8], η αναγνώριση πινακίδων οχημάτων [9], η ταυτοποίηση δακτυλικών αποτυπωμάτων [10], καθώς και πολλές άλλες βιομηχανικές και εφαρμογές ασφάλειας.

Η βελτίωση της ποιότητας μιας εικόνας μπορεί να επιτευχθεί μέσω της προσαρμογής είτε του υλικού (hardware) είτε του λογισμικού (software). Οι hardware-based μέθοδοι, αν και πιο αποδοτικές σε ορισμένες περιπτώσεις, είναι συχνά πιο ακριβές και πολύ λιγότερο ευέλικτες. Αντίθετα, οι software-based μέθοδοι [11] είναι πιο οικονομικές και έχουν τη δυνατότητα εφαρμογής σε ήδη υπάρχουσες εικόνες ή συστήματα, καθιστώντας τις ιδανικές για πολλές περιπτώσεις χρήσης. Για τον λόγο αυτό, οι μέθοδοι που βασίζονται στο λογισμικό έχουν κυριαρχήσει στην επιστημονική έρευνα και τις πρακτικές εφαρμογές της υπερανάλυσης.

Αξιοσημείωτο είναι, πως η υπερανάλυση εικόνας δεν αναφέρεται απλώς στη αύξηση των διαστάσεων της εικόνας, αλλά στην αύξηση του αριθμού των εικονοστοιχείων (pixels) ανά μονάδα επιφάνειας της εικόνας. Αντίθετα με τις απλές τεχνικές μεγέθυνσης (όπως η bicubic interpolation), οι οποίες αυξάνουν τις διαστάσεις της εικόνας προσθέτοντας εικονοστοιχεία μέσω παρεμβολής χωρίς να εισάγουν νέα πληροφορία, το Super Resolution αυξάνει την πραγματική πυκνότητα των εικονοστοιχείων, συμπληρώνοντας νέες λεπτομέρειες που δεν

υπήρχαν στην αρχική εικόνα. Αυτό επιτρέπει τη δημιουργία εικόνων που περιέχουν περισσότερη πληροφορία και μεγαλύτερη ευκρίνεια.

Η υπερανάλυση εικόνας έχει γνωρίσει τεράστια πρόοδο τα τελευταία χρόνια, χάρη στην ανάπτυξη νέων αλγορίθμων τεχνητής νοημοσύνης, όπως τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks, CNNs) [12] καθώς και τα Παραγωγικά Αντιπαραθετικά Δίκτυα (Generative Adversarial Networks, GANs) [13]. Αυτές οι μέθοδοι επιτρέπουν την ανακατασκευή λεπτομερειών με υψηλή ακρίβεια, διατηρώντας ταυτόχρονα τη φυσικότητα και την ποιότητα της εικόνας. Παρά τις προκλήσεις, όπως η διατήρηση των υφιστάμενων χαρακτηριστικών και η αποφυγή τεχνητών παραμορφώσεων (artifacts), η υπερανάλυση συνεχίζει να αποτελεί έναν από τους πιο ελπιδοφόρους τομείς της όρασης υπολογιστών. Στην παρούσα εργασία θα εξετάσουμε την εφαρμογή των Μοντέλων Διάχυσης (Diffusion Models) [14] σε αυτόν τον τομέα.




Σχήμα 2.1: Σύγκριση δορυφορικής εικόνας της πόλης του Παρισιού χαμηλής ανάλυσης (αριστερά) με την αντίστοιχη εικόνα υψηλής ανάλυσης (δεξιά), αναδεικνύοντας την ενισχυμένη ευκρίνεια και λεπτομέρεια που επιτυγχάνονται μέσω τεχνικών επεξεργασίας εικόνας.

2.2 Ανίχνευση Αντικειμένων

Η ανίχνευση αντικειμένων (Object Detection [15]) αποτελεί θεμελιώδη τεχνική της όρασης υπολογιστών, με σκοπό τον εντοπισμό και την κατηγοριοποίηση αντικειμένων σε ψηφιακές εικόνες ή βίντεο. Συνδυάζει δύο επιμέρους εργασίες — τον προσδιορισμό της θέσης και της κατηγορίας κάθε αντικειμένου — καθιστώντας την απαραίτητο εργαλείο για την κατανόηση του οπτικού περιεχομένου σε στατικές και δυναμικές σκηνές.

Η μέθοδος αυτή έχει ευρεία εφαρμογή σε διάφορους τομείς, όπως η αυτόνομη οδήγηση, τα συστήματα επιτήρησης και η ρομποτική. Μπορεί να χρησιμοποιηθεί τόσο σε στατικές εικόνες και βίντεο όσο και σε πραγματικό χρόνο. Η ανάπτυξη των Συνελικτικών Νευρωνικών Δικτύων (CNNs) έχει συμβάλει στην δημιουργία και την εξέλιξη πρωτοποριακών δικτύων

ανίχνευσης αντικειμένων τα οποία είναι σε θέση να ανιχνεύουν πολύπλοκα οπτικά χαρακτηριστικά. Πρωτοποριακοί αλγόριθμοι, όπως οι Faster R-CNN [16], YOLO (You Only Look Once) [1] και SSD (Single Shot MultiBox Detector) [17], έχουν προσφέρει υψηλή ακρίβεια και ταχύτητα στην ανίχνευση αντικειμένων.



Σχήμα 2.2: Ανίχνευση αντικειμένων σε αστική οδό, με εντοπισμό οχημάτων, ποδηλάτων, πεζών και φωτεινού σηματοδότη μέσω αριθμημένων πλαισίων. [1]


Πρόσφατα, η χρήση αρχιτεκτονικών μετασχηματιστών (transformers) [18] έχει φέρει επανάσταση στο πεδίο της ανίχνευσης αντικειμένων. Αυτά τα μοντέλα καταργούν την ανάγκη για παραδοσιακές προσεγγίσεις προτάσεων περιοχών (region proposals), χρησιμοποιώντας παγκόσμια αναπαράσταση χαρακτηριστικών της εικόνας και επιτυγχάνοντας εξαιρετική απόδοση.

Η ανίχνευση αντικειμένων συνεχίζει να διαδραματίζει καθοριστικό ρόλο στην όραση υπολογιστών, επεκτείνοντας τα όριά της μέσω νέων τεχνολογιών και ανοίγοντας το δρόμο για ακόμη πιο καινοτόμες εφαρμογές σε διάφορους τομείς της επιστήμης και της τεχνολογίας.

2.3 Συνελκτικά Νευρωνικά Δίκτυα

Τα Convolutional Neural Networks (CNNs) [12] αποτελούν μια εξειδικευμένη κατηγορία μοντέλων βαθιάς μάθησης, σχεδιασμένη για την επεξεργασία δεδομένων με χωρικές ιδιότητες, όπως εικόνες και βίντεο. Εμπνευσμένα από τον τρόπο λειτουργίας του ανθρώπινου οπτικού συστήματος, τα CNNs χρησιμοποιούν ιεραρχικά επίπεδα για να μάθουν αυτόματα χωρικές ιεραρχίες χαρακτηριστικών από ακατέργαστα δεδομένα εισόδου. Σε αντίθεση με τα παραδοσιακά πλήρως συνδεδεμένα νευρωνικά δίκτυα, τα CNNs αξιοποιούν συνελκτικά επίπεδα, επίπεδα υποδειγματοληψίας (pooling layers) και πλήρως συνδεδεμένα επίπεδα (fully connected layers) για την αποδοτική εξαγωγή τόσο τοπικών όσο και γενικών προτύπων.

Η βασική λειτουργία των CNNs είναι η συνέλιξη (convolution operation), κατά την οποία



Σχήμα 2.3: Ενδεικτική αρχιτεκτονική συνελκτικού νευρωνικού δικτύου.

εφαρμόζεται ένας πυρήνας (filter ή kernel) στην εικόνα εισόδου για την εξαγωγή σημαντικών χαρακτηριστικών. Πιο συγκεκριμένα, για μια δοθείσα εικόνα $I(x, y)$ και έναν συνελκτικό πυρήνα $K(a, b)$, η πράξη της συνέλιξης ορίζεται ως:

$$S(x, y) = \sum_a \sum_b I(x - a, y - b) K(a, b)$$

όπου $S(x, y)$ είναι ο χάρτης χαρακτηριστικών εξόδου μετά την εφαρμογή της συνέλιξης, $I(x, y)$ η εικόνα εισόδου και $K(a, b)$ ο συνελκτικός πυρήνας (ένας μικρός πίνακας εκπαιδευσιμων βαρών). Οι αθροίσεις αφορούν τις διαστάσεις του πυρήνα.

Μετά τη συνέλιξη, τα CNNs εφαρμόζουν επίπεδα υποδειγματοληψίας (pooling layers) για τη μείωση της διάστασης των χαρτών χαρακτηριστικών, διατηρώντας παράλληλα τις πιο σημαντικές πληροφορίες. Η πιο συχνά χρησιμοποιούμενη τεχνική είναι η μέγιστη υποδειγματοληψία (Max Pooling), η οποία ορίζεται ως:

$$P(x, y) = \max_{i,j \in R} S(x + i, y + j)$$

όπου R είναι η περιοχή υποδειγματοληψίας (π.χ., παράθυρο 2×2). Η μέγιστη υποδειγματοληψία διατηρεί τα πιο σημαντικά χαρακτηριστικά, μειώνοντας ταυτόχρονα το υπολογιστικό κόστος και τον κίνδυνο υπερεκπαίδευσης.

Αφού εξαχθούν τα υψηλού επιπέδου χαρακτηριστικά μέσω πολλαπλών επιπέδων συνέλιξης και υποδειγματοληψίας, το τελευταίο στάδιο περιλαμβάνει πλήρως συνδεδεμένα επίπεδα (FC layers). Οι χάρτες χαρακτηριστικών μετατρέπονται σε μονοδιάστατο διάνυσμα και υποβάλλονται σε επεξεργασία από ένα κλασικό νευρωνικό δίκτυο προώθησης (feedforward neural network) για ταξινόμηση. Η τελική πρόβλεψη προκύπτει μέσω της συνάρτησης ενεργοποίησης softmax:

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

Τα CNNs έχουν επιφέρει σημαντικές εξελίξεις στον τομέα της όρασης υπολογιστών, επιτρέποντας πρωτοποριακές εφαρμογές στην ταξινόμηση εικόνων, την ανίχνευση αντικειμένων, την αναγνώριση προσώπων και την ιατρική ανάλυση εικόνων. Βασικές αρχιτεκτονικές, όπως το AlexNet [19], το VGGNet [20], το ResNet [21], και τα Inception networks [22] έχουν βελτιστοποιήσει την απόδοση σε ποικίλες αναγνωριστικές εργασίες. Οι αρχιτεκτονικές αυτές

διαφέρουν ως προς το βάθος, την υπολογιστική πολυπλοκότητα και τις τεχνικές βελτιστοποίησης, αλλά όλες βασίζονται στη θεμελιώδη αρχή της ιεραρχικής εξαγωγής χαρακτηριστικών μέσω συνελκτικών διεργασιών.

Ένα από τα βασικά πλεονεκτήματα των CNNs είναι η ικανότητά τους να μαθαίνουν αυτόματα αναπαραστάσεις χαρακτηριστικών, εξαλείφοντας την ανάγκη για χειροκίνητη εξαγωγή τους. Η εισαγωγή της μεταφοράς μάθησης (transfer learning) έχει ενισχύσει ακόμη περισσότερο τη χρηστικότητα τους, επιτρέποντας την αξιοποίηση προεκπαιδευμένων μοντέλων σε εξειδικευμένες εργασίες με περιορισμένα δεδομένα. Επιπλέον, η ενσωμάτωση μηχανισμών προσοχής (attention mechanisms) και η ανάπτυξη υβριδικών μοντέλων βασισμένων σε μετασχηματιστές (transformer-based hybrid models) έχουν βελτιώσει περαιτέρω την ικανότητα των CNNs να γενικεύουν αποτελεσματικά σε διαφορετικά σύνολα δεδομένων.

Παρά την επιτυχία τους, τα CNNs αντιμετωπίζουν ορισμένες προκλήσεις, όπως η υπολογιστική πολυπλοκότητα, η ευαισθησία σε επιθέσεις παραπλάνησης (adversarial attacks) και η ανάγκη μεγάλων συνόλων δεδομένων με επισημάνσεις (labeled datasets) για αποτελεσματική εκπαίδευση. Η έρευνα επικεντρώνεται στη βελτίωση της αποδοτικότητας των CNNs, με την ανάπτυξη τεχνικών όπως η συμπίεση μοντέλων (model compression) και η αυτοεπιβλεπόμενη μάθηση (self-supervised learning).

Τα CNNs εξακολουθούν να αποτελούν θεμέλιο λίθο της έρευνας στη βαθιά μάθηση, υποστηρίζοντας εφαρμογές αιχμής σε τομείς όπως η αυτόνομη οδήγηση, η ιατρική διάγνωση, η επιτήρηση και η ασφάλεια. Καθώς η τεχνητή νοημοσύνη εξελίσσεται, τα CNNs συνυπάρχουν και εξελίσσονται παράλληλα με νεότερα αρχιτεκτονικά πρότυπα, όπως οι Vision Transformers (ViTs) και τα νευρωνικά δίκτυα βασισμένα σε γραφήματα (graph-based neural networks), συμβάλλοντας από κοινού στη διαμόρφωση του μέλλοντος της υπολογιστικής όρασης και της τεχνητής νοημοσύνης.

2.4 U-Net

Το U-Net [23] είναι ένα πλήρως συνελκτικό νευρωνικό δίκτυο (Fully Convolutional Network - FCN), ειδικά σχεδιασμένο για εργασίες τμηματοποίησης εικόνας. Έχει υιοθετηθεί ευρέως στον τομέα της ιατρικής απεικόνισης. Παρουσιάστηκε από τους Ronneberger et al. το 2015 και έκτοτε έχει καθιερωθεί ως μία από τις πιο διαδεδομένες αρχιτεκτονικές για σημασιολογική τμηματοποίηση, χάρη στην ικανότητά του να αποτυπώνει τόσο πληροφορία υψηλού επιπέδου όσο και χωρικές λεπτομέρειες, μέσω μιας συμμετρικής αρχιτεκτονικής τύπου κωδικοποιητή-αποκωδικοποιητή.

Η αρχιτεκτονική του U-Net αποτελείται από δύο κύρια μέρη:

- **Κωδικοποιητής (Contracting Path):** Εξάγει χαρακτηριστικά υψηλού επιπέδου μέσω συνελίξεων και υποδειγματοληψίας.
- **Αποκωδικοποιητής (Expanding Path):** Ανακατασκευάζει τον χάρτη τμηματοποίησης μέσω upsampling, με τη βοήθεια συνδέσεων παράκαμψης (skip connections) από τα αντίστοιχα στάδια του κωδικοποιητή.

Μια απεικόνιση της αρχιτεκτονικής του U-Net παρουσιάζεται στο Σχήμα 2.4.

Κωδικοποιητής Το μονοπάτι του κωδικοποιητή αποτελείται από επαναλαμβανόμενες συνελικτικές πράξεις 3×3 , ενεργοποίηση ReLU, και υποδειγματοληψία μέσω max pooling 2×2 :

$$S_{l+1} = \max_{i,j \in R} (W_l * S_l + b_l),$$

όπου S_l είναι ο χάρτης χαρακτηριστικών στο επίπεδο l , W_l ο συνελκτικός πυρήνας, b_l η μετατόπιση και R η περιοχή υποδειγματοληψίας.

Αποκωδικοποιητής Ο αποκωδικοποιητής αντικατοπτρίζει τον κωδικοποιητή και αυξάνει σταδιακά τη χωρική ανάλυση μέσω upsampling, που επιτυγχάνεται με ανεστραμμένες συνελίξεις ή παρεμβολή, ακολουθούμενη από συμβατική συνελκτική πράξη:

$$U_l = \text{Upsample}(S_l),$$

Οι συνδέσεις παράκαμψης επιτρέπουν στο δίκτυο να συνδυάζει πληροφορία υψηλής και χαμηλής ανάλυσης, βελτιώνοντας την ακρίβεια εντοπισμού.

Τελικό Επίπεδο Εξόδου Ένα συνελκτικό επίπεδο 1×1 αντιστοιχίζει τα χαρακτηριστικά στις επιθυμητές κατηγορίες, ενώ η ενεργοποίηση softmax αποδίδει πιθανότητες ανά εικονοστοιχείο:

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}},$$

όπου p_i είναι η πιθανότητα το εικονοστοιχείο i να ανήκει σε μία κατηγορία.

Το U-Net έχει επιδείξει υψηλή απόδοση σε διάφορους τομείς, από την τμηματοποίηση εγκεφαλικών όγκων [24] [25] και πνευμονικών οζιδίων [26], έως την εξαγωγή οδικών δικτύων σε δορυφορικές εικόνες [27] και την αναγνώριση λωρίδων σε αυτόνομα οχήματα [28] [29]. Χρήσεις βρίσκονται επίσης στη γεωργία [30] [29] και στην περιβαλλοντική παρακολούθηση [31] [32].


Ωστόσο, το μοντέλο έχει και περιορισμούς. Η πολυπλοκότητά του μπορεί να απαιτεί αυξημένους πόρους, ενώ η τμηματοποίηση μικρών αντικειμένων μπορεί να είναι ανεπαρκής. Επίσης, χωρίς τεχνικές κανονικοποίησης ή ενίσχυσης δεδομένων, είναι πιθανό να προκύψει υπερπροσαρμογή.

Για την αντιμετώπιση αυτών των θεμάτων έχουν προταθεί παραλλαγές όπως το U-Net++ [33], το Attention U-Net [34] και το 3D U-Net [35].

Συνοψίζοντας, το U-Net αποτελεί θεμελιώδη αρχιτεκτονική στην τμηματοποίηση εικόνας, προσφέροντας έναν ισορροπημένο συνδυασμό κατανόησης παγκόσμιου περιεχομένου και διατήρησης λεπτομερειών.

2.5 Knowledge Distillation

Η μέθοδος *Knowledge Distillation* [36] αποτελεί τεχνική συμπίεσης μοντέλων, κατά την οποία ένα μικρότερο, πιο αποδοτικό μοντέλο, γνωστό ως *μαθητής*, εκπαιδεύεται ώστε να



Σχήμα 2.4: Αρχιτεκτονική U-Net: συμμετρική δομή κωδικοποιητή-αποκωδικοποιητή για σημασιολογική τμηματοποίηση.

μιμηθεί τη συμπεριφορά ενός μεγαλύτερου και ισχυρότερου μοντέλου, του *διδάσκοντα*.

Αντί να βασίζεται αποκλειστικά στις ετικέτες αληθείας, ο μαθητής αξιοποιεί τις *soft labels* του διδάσκοντα — κατανομές πιθανοτήτων που περιλαμβάνουν λεπτομερή πληροφορία για τις σχετικές ομοιότητες μεταξύ των κλάσεων. Η κατανομή αυτή υπολογίζεται μέσω της συνάρτησης softmax με παραμετροποίηση θερμοκρασίας:

$$p_T(y_k|x) = \frac{\exp(z_k^T/T)}{\sum_j \exp(z_j^T/T)} \quad (2.1)$$

όπου T είναι η παράμετρος θερμοκρασίας που «εξομαλύνει» την κατανομή. Ο μαθητής εκπαιδεύεται ώστε να ελαχιστοποιήσει τη διαφορά μεταξύ των δικών του προβλέψεων και εκείνων του διδάσκοντα, μέσω της απόκλισης Kullback-Leibler (KL) [37]:

$$\mathcal{L}_{KD} = T^2 \sum_k p_T(y_k|x) \log \frac{p_T(y_k|x)}{p_S(y_k|x)} \quad (2.2)$$

όπου $p_S(y_k|x)$ είναι η προβλεπόμενη πιθανότητα του μαθητή. Για πιο ολοκληρωμένη εκπαίδευση, η παραπάνω απώλεια μπορεί να συνδυαστεί με την παραδοσιακή απώλεια διασταυρωμένης εντροπίας:

$$\mathcal{L} = (1 - \beta)\mathcal{L}_{CE} + \beta\mathcal{L}_{KD} \quad (2.3)$$

με την παράμετρο β να ρυθμίζει τη συμβολή των δύο όρων.

Αυτή η προσέγγιση επιτρέπει στον μαθητή να πετυχαίνει συγκρίσιμη απόδοση με το μοντέλο διδάσκοντα, διατηρώντας ταυτόχρονα μικρότερο μέγεθος και χαμηλότερες απαιτήσεις υπολογιστικών πόρων — καθιστώντας την κατάλληλη για εφαρμογές σε κινητές συσκευές ή ενσωματωμένα συστήματα.

2.6 Μοντέλα Διάχυσης

Τα μοντέλα διάχυσης (Diffusion Models) αποτελούν μια κατηγορία παραγωγικών μοντέλων (generative models), τα οποία έχουν σημειώσει εξαιρετικά αποτελέσματα σε εργασίες όπως η σύνθεση εικόνων, η μετατροπή κειμένου σε εικόνα και η απαλοιφή θορύβου από δεδομένα. Σε αντίθεση με παραδοσιακές προσεγγίσεις, όπως τα GANs και οι VAEs, τα μοντέλα διάχυσης βασίζονται σε μια στοχαστική διαδικασία, κατά την οποία θόρυβος μετατρέπεται σταδιακά σε δομημένα δεδομένα μέσω μιας ακολουθίας εκπαιδευμένων βημάτων αποθορυβοποίησης. Σημαντικές εξελίξεις, όπως τα Denoising Diffusion Probabilistic Models (DDPMs) και η προσέγγιση Denoising Score Matching (DSM), έχουν εντυπωσιακά ενισχύσει την ποιότητα και τον έλεγχο των παραγόμενων δειγμάτων, καθιστώντας τα μοντέλα διάχυσης ιδανικά για εφαρμογές υψηλής πιστότητας [38, 39, 40].

Μαθηματική Διατύπωση


Τα μοντέλα διάχυσης υλοποιούν μία διαδικασία δύο σταδίων: μια προς τα εμπρός διαδικασία και μία αντίστροφη (ανακατασκευή).

Προς τα Εμπρός Διαδικασία Δεδομένου αρχικού δείγματος $\mathbf{x}_0 \sim q(\mathbf{x})$, προστίθεται σταδιακά Γκαουσιανός θόρυβος σε T βήματα, σύμφωνα με ένα προκαθορισμένο πρόγραμμα διασποράς $\beta_1, \dots, \beta_T$. Έτσι, παράγεται μία ακολουθία όλο και πιο θορυβωδών δειγμάτων $\mathbf{x}_1, \dots, \mathbf{x}_T$:

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}),$$

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}),$$

όπου το $\beta_t \in (0, 1)$ ελέγχει την ένταση του θορύβου σε κάθε χρονικό βήμα.



Σχήμα 2.5: Απεικόνιση της αλυσίδας Μάρκο για την προς τα εμπρός και αντίστροφη διαδικασία διάχυσης.


Parametrization Trick Ορίζοντας $\alpha_t = 1 - \beta_t$ και $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$, κάθε θορυβωμένο δείγμα μπορεί να υπολογιστεί απευθείας ως:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}).$$

Αντίστροφη Διαδικασία Για να δημιουργηθεί ένα νέο δείγμα, ξεκινάμε από καθαρό θόρυβο $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$, και προσπαθούμε να αναστρέψουμε τη διάχυση μέσω μιας μοντελοποιημένης αλυσίδας:

$$p_{\theta}(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t),$$

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \sigma_{\theta}^2(\mathbf{x}_t, t)\mathbf{I}).$$



Σχήμα 2.6: Εικονογράφηση της αντίστροφης διαδικασίας διάχυσης.

Εκπαίδευση Μοντέλου Διάχυσης

Η εκπαίδευση βασίζεται στη μεγιστοποίηση της πιθανοφάνειας των δεδομένων μέσω του evidence lower bound (ELBO):

$$\log p_{\theta}(x_0) \geq \mathbb{E}_{q(x_{1:T}|x_0)}[\log p_{\theta}(x_0|x_1)] - D_{KL}(q(x_T|x_0) || p(x_T)) - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)}[D_{KL}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t))]. \quad (2.4)$$

Αναπαραμετροποιημένη Απώλεια Εφόσον έχουμε υπό συνθήκη γνώση του x_0 , μπορούμε να εκφράσουμε με υπολογίσιμο τρόπο την κατανομή της αντίστροφης διαδικασίας ως:

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \mu_t(x_t, x_0), \tilde{\beta}_t \mathbf{I}), \quad (2.5)$$

όπου:

$$\tilde{\beta}_t = \frac{1 - \bar{a}_{t-1}}{1 - \bar{a}_t} \beta_t, \quad \mu_t(x_t, x_0) = \frac{\sqrt{\bar{a}_{t-1}} \beta_t}{1 - \bar{a}_t} x_0 + \frac{\sqrt{\bar{a}_t} (1 - \bar{a}_{t-1})}{1 - \bar{a}_t} x_t. \quad (2.6)$$

Οι συντελεστές αυτοί εξαρτώνται αποκλειστικά από το πρόγραμμα μεταβολής της διασποράς και μπορούν να υπολογιστούν εκ των προτέρων.

Απώλεια Διόρθωσης Θορύβου Αν $\epsilon_\theta(x_t, t)$ είναι το νευρωνικό δίκτυο που εκτιμά τον θόρυβο, η απώλεια ορίζεται ως:

$$L_t = \mathbb{E}_{x_0, t, \epsilon} \left[\frac{\beta_t}{2\bar{a}_t(1 - \bar{a}_t)} \|\epsilon - \epsilon_\theta(x_t, t)\|_2^2 \right]. \quad (2.7)$$

Απλοποιημένη Εκδοχή Οι Ho et al. [14], στη μελέτη τους το 2020, πρότειναν την απλοποιημένη έκδοση:

$$L_t^{simple} = \mathbb{E}_{x_0, t, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{a}_t} x_0 + \sqrt{1 - \bar{a}_t} \epsilon, t \right) \right\|_2^2 \right], \quad (2.8)$$

η οποία είναι πιο σταθερή και αποδοτική στην πράξη.

Εκμάθηση Διασποράς Αρχικά, τα μοντέλα μάθαιναν μόνο τη μέση τιμή της αντίστροφης κατανομής, με σταθερή διασπορά. Οι Nichol et al. [41] επεκτείνουν τη διαδικασία επιτρέποντας στο μοντέλο να προβλέπει και τη διασπορά Σ_θ , βελτιώνοντας την ακρίβεια των δειγμάτων.

Algorithm 1 Training	Algorithm 2 Sampling
1: repeat 2: $x_0 \sim q(x_0)$ 3: $t \sim \text{Uniform}(\{1, \dots, T\})$ 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 5: Take gradient descent step on $\nabla_\theta \ \epsilon - \epsilon_\theta(\sqrt{\bar{a}_t} x_0 + \sqrt{1 - \bar{a}_t} \epsilon, t)\ _2^2$ 6: until converged	1: $x_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 2: for $t = T, \dots, 1$ do 3: $z \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $z = \mathbf{0}$ 4: $x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z$ 5: end for 6: return x_0

Σχήμα 2.7: Διαδικασία εκπαίδευσης και δειγματοληψίας στα μοντέλα διάχυσης.

Συμπερασματικά Τα μοντέλα διάχυσης προσφέρουν μια θεωρητικά θεμελιωμένη και σταθερή μέθοδο παραγωγής δεδομένων, με εντυπωσιακές επιδόσεις σε εφαρμογές όπως η παραγωγή υψηλής ευκρίνειας εικόνων. Η σταδιακή φύση της παραγωγής τα καθιστά ιδιαίτερα κατάλληλα για εφαρμογές όπως η υπερανάλυση εικόνας, όπου απαιτείται ρεαλιστική και λεπτομερής ανακατασκευή.

Μέθοδος και αποτελέσματα

Στο κεφάλαιο αυτό περιγράφονται τα σύνολα δεδομένων που χρησιμοποιήθηκαν στο πλαίσιο των πειραμάτων μας, με σκοπό την εφαρμογή και την αξιολόγηση των μοντέλων διάχυσης στον τομέα της υπερανάλυσης εικόνας. Αρχικά, παρουσιάζονται συνοπτικά τα σύνολα δεδομένων, συνοδευόμενα από ενδεικτικά παραδείγματα εικόνων. Στη συνέχεια, αναλύεται διεξοδικά η διαδικασία προετοιμασίας των δεδομένων για την εκπαίδευση των μοντέλων, καθώς και η μεθοδολογία που ακολουθήθηκε για την υλοποίηση της προτεινόμενης αρχιτεκτονικής.

Επιπλέον, περιγράφεται αναλυτικά το προτεινόμενο pipeline, το οποίο συνδυάζει την υπερανάλυση με τεχνικές εντοπισμού αντικειμένων, και παρουσιάζονται τα αποτελέσματα των πειραμάτων τόσο σε ποσοτικό όσο και σε ποιοτικό επίπεδο. Η αξιολόγηση συνοδεύεται από συγκριτικούς πίνακες και οπτικές αναπαραστάσεις, οι οποίες αναδεικνύουν τις διαφορές απόδοσης μεταξύ της βασικής και της προτεινόμενης μεθόδου.


3.1 Σύνολα Δεδομένων

3.1.1 Brats2023

Οι όγκοι του εγκεφάλου, και ιδιαίτερα το γλοιοβλάστωμα και το διάχυτο αστροκύτωμα με μοριακά χαρακτηριστικά γλοιοβλαστώματος (γνωστό και ως αστροκύτωμα 4ου βαθμού σύμφωνα με τον Παγκόσμιο Οργανισμό Υγείας - WHO) [42], συγκαταλέγονται στους πιο επιθετικούς και θανατηφόρους πρωτοπαθείς κακοήγεις όγκους του κεντρικού νευρικού συστήματος στους ενήλικες, με διάμεση επιβίωση περίπου 15 μηνών. Αυτοί οι όγκοι παρουσιάζουν έντονη ετερογένεια σε μορφολογία και ιστολογικά χαρακτηριστικά, ενώ είναι συχνά ανθεκτικοί στη θεραπεία, λόγω δυσκολιών στη φαρμακευτική πρόσβαση στον εγκέφαλο και της βιολογικής τους πολυπλοκότητας.

Ο ετήσιος διαγωνισμός Brain Tumor Segmentation (BraTS) στοχεύει στην αξιολόγηση και βελτίωση σύγχρονων αλγορίθμων για την αυτόματη κατάτμηση όγκων του εγκεφάλου, παρέχοντας ένα πρότυπο σύνολο δεδομένων με υψηλής ποιότητας επισημάνσεις.

Το BraTS (Brain Tumor Segmentation dataset) [43] αποτελεί ένα ευρέως χρησιμοποιούμενο σύνολο δεδομένων για την κατάτμηση όγκων εγκεφάλου από πολυμορφικές μαγνητικές τομογραφίες (MRI). Περιλαμβάνει τέσσερις τύπους απεικόνισης: T1-weighted, T1 with contrast (T1c), T2-weighted και FLAIR [44, 45, 46], οι οποίοι συνδυάζονται για την ολοκληρωμένη απεικόνιση της εγκεφαλικής ανατομίας και παθολογίας.



Σχήμα 3.1: Μαγνητικές τομογραφίες εγκεφάλων με παρουσία όγκων διαφόρων μεγεθών.

Το BraTS διακρίνεται για την κλινική του εγκυρότητα, καθώς οι επισημάνσεις έχουν πραγματοποιηθεί από ειδικούς, σε επίπεδο εικονοστοιχείων. Το υψηλό επίπεδο ακρίβειας είναι ζωτικής σημασίας για την εκπαίδευση αλγορίθμων βιοϊατρικής τεχνητής νοημοσύνης, δεδομένων των προκλήσεων που σχετίζονται με τη διαθεσιμότητα καλά επισημασμένων ιατρικών δεδομένων [4]. Το σύνολο υποστηρίζει πλήθος εφαρμογών όπως κατάτμηση, πρόβλεψη επιβίωσης και ανάλυση εξέλιξης όγκου, και είναι διαχωρισμένο σε σύνολα training, validation και testing.

Στο πλαίσιο αυτής της εργασίας, χρησιμοποιήθηκε η έκδοση BraTS2023, η οποία εμπλουτίζει προηγούμενες εκδόσεις (π.χ. BraTS2021, BraTS2022) με επιπλέον περιστατικά, βελτιωμένες επισημάνσεις και ενισχυμένες απεικονιστικές μεθόδους. Ο στόχος της είναι η προώθηση προηγμένων μεθόδων αυτόματης κατάτμησης, με εφαρμογές σε διάγνωση, παρακολούθηση και σχεδιασμό θεραπείας για ασθενείς με όγκους εγκεφάλου [47, 5, 6].


Προετοιμασία Δεδομένων

Κατά την διάρκεια της προεπεξεργασίας των δεδομένων του συνόλου BraTS2023 για την εκπαίδευση του μοντέλου, δόθηκε έμφαση στη σωστή διαχείριση και προετοιμασία των εικόνων για την αποτελεσματική κατάτμηση των όγκων εγκεφάλου. Τα δεδομένα παρέχονται σε μορφή .nii (NIfTI - Neuroimaging Informatics Technology Initiative), η οποία είναι ειδικά σχεδιασμένη για δεδομένα ιατρικής απεικόνισης. Η μορφή αυτή υποστηρίζει τρισδιάστατες ή τετραδιάστατες απεικονίσεις και παρέχει δυνατότητα αποθήκευσης τόσο της έντασης του κάθε voxel (το τρισδιάστατο ανάλογο του pixel) όσο και των μεταδεδομένων, όπως οι διαστάσεις και η χωρική ανάλυση, σε ένα ενιαίο αρχείο.

Αρχικά, τα δεδομένα φορτώθηκαν και αναγνώστηκαν με τη χρήση της βιβλιοθηκής Nibabel, η οποία είναι κατάλληλη για τη διαχείριση αρχείων NIfTI. Επειδή οι εικόνες περιλάμβαναν τέσσερις διαφορετικές απεικονιστικές μεθόδους (T1, T1ce, T2, FLAIR), όλα τα modalities για κάθε ασθενή ήταν ευθυγραμμισμένα μεταξύ τους (co-registered), διευκολύνοντας έτσι την ανάλυση τους.

Για να προετοιμαστούν τα δεδομένα για εκπαίδευση στο 2D μοντέλο μας, κάναμε split

τα 240x240x155 tensors, που είχαν δημιουργηθεί με τη βοήθεια του nibabel, ως προς την τρίτη διάσταση (βάθος), με αποτέλεσμα κάθε τομογραφία να διαχωριστεί σε 155 διδιάστατες (2D) εικόνες. Δεδομένου ότι το μοντέλο μας απαιτεί εισόδους με διαστάσεις 256x256 pixels για την εκπαίδευση, εφαρμόστηκε padding στις εικόνες, ώστε να προσαρμοστούν στις απαιτούμενες διαστάσεις. Αυτή η διαδικασία διασφάλισε ότι όλες οι εικόνες είχαν ομοιόμορφες διαστάσεις, χωρίς επίσης να χαθεί η οποιαδήποτε πληροφορία από τις αρχικές τομογραφίες.



Σχήμα 3.2: Αποτελέσματα του split σε διάστημα 30 εικόνων

3.1.2 Traffic Lights

Η αυτόνομη οδήγηση αποτελεί έναν από τους ταχύτερα αναπτυσσόμενους τομείς της τεχνητής νοημοσύνης, με στόχο τη δημιουργία ασφαλέστερων και πιο αποδοτικών μεταφορών. Ένα από τα σημαντικότερα τεχνικά εμπόδια που πρέπει να ξεπεραστούν είναι η αξιόπιστη ανίχνευση και αναγνώριση των φωτεινών σηματοδοτών σε πραγματικό χρόνο, καθώς αυτοί παίζουν κρίσιμο ρόλο στη ρύθμιση της κυκλοφορίας και στην αποφυγή ατυχημάτων. Η ακριβής αναγνώριση των φωτεινών σηματοδοτών είναι θεμελιώδης τόσο για την κατανόηση των κυκλοφοριακών συνθηκών όσο και για τη σωστή αλληλεπίδραση των αυτόνομων οχημάτων με το περιβάλλον τους.

Στο πλαίσιο της εκπαίδευσης του μοντέλου μας, με σκοπό την βελτίωσή του στον τομέα της αυτόματης οδήγησης χρειάστηκε ένας σημαντικός αριθμός φαναριών. Έτσι, διεξήχθη έρευνα στο διαδίκτυο ώστε να βρεθούν σύνολα δεδομένων τα οποία να περιέχουν φωτεινούς σηματοδότες σε υψηλή ανάλυση. Εν συνεχεία, τα συγκεντρώσαμε και δημιουργήσαμε ένα custom σύνολο δεδομένων αποτελούμενο από φωτεινούς σηματοδότες για τους σκοπούς της εργασίας αυτής. Περιλαμβάνει εικόνες από πραγματικές οδικές σκηνές, λαμβάνοντας υπόψη διαφορετικές καιρικές συνθήκες, ποικίλα επίπεδα φωτισμού (μέρα, νύχτα, σούρουπο), καθώς και διάφορους τύπους και χρωματικούς συνδυασμούς φαναριών που χρησιμοποιούνται σε διαφορετικές χώρες.

Παρακάτω αναφέρονται τα σύνολα δεδομένων από τα οποία εξήχθησαν τα φανάρια που χρησιμοποιήθηκαν για την εκπαίδευση του μοντέλου μας και στη συνέχεια αναφέρουμε την συνολική διαδικασία προεπεξεργασίας που υπέστησαν οι εικόνες.


COCO

Το σύνολο δεδομένων COCO (Common Objects in Context) [48] είναι ένα σύνολο δεδομένων μεγάλης κλίμακας που προορίζεται κυρίως για τις μεθόδους της ανίχνευσης αντικειμένων και της κατάτμησης εικόνας. Περιέχει πάνω από 330.000 εικόνες, καθεμία από τις οποίες είναι επισημασμένη με 80 κατηγορίες αντικειμένων και 5 λεζάντες που περιγράφουν τη σκηνή. Το σύνολο δεδομένων COCO χρησιμοποιείται ευρέως στην έρευνα της όρασης

Πίνακας 3.1: *Traffic Lights Detection Datasets and Number of Images*

Dataset	Number of Images
COCO	1,153
Traffic Lights Detection Dataset	3,210
Lisa	944
BDD100K	1098
Bosch	213
Google Open Images	1,539
Total	8,157

υπολογιστών και έχει χρησιμοποιηθεί για την εκπαίδευση και αξιολόγηση πολλών μοντέλων ανίχνευσης και τμηματοποίησης αντικειμένων τελευταίας τεχνολογίας.


Σχήμα 3.3: *Παραδείγματα εικόνων που ανήκουν το COCO*

BDD100K

Το BDD100K [49] είναι ένα εκτενές σύνολο δεδομένων που περιλαμβάνει 100.000 βίντεο οδήγησης, το καθένα διάρκειας περίπου 40 δευτερολέπτων, με ανάλυση 720p και 30 καρέ ανά δευτερόλεπτο. Αυτό το σύνολο δεδομένων καλύπτει μια ποικιλία σεναρίων οδήγησης, καιρικών συνθηκών και ωρών της ημέρας, παρέχοντας μια πλούσια βάση για την ανάπτυξη και αξιολόγηση συστημάτων αυτόνομης οδήγησης. Οι επισημάνσεις περιλαμβάνουν διάφορες εργασίες, όπως ανίχνευση αντικειμένων, σήμανση λωρίδων, τμηματοποίηση περιοχών οδήγησης και άλλες, διευκολύνοντας την έρευνα στην ετερογενή πολυ-εργασιακή μάθηση.

Bosch

Το Bosch Small Traffic Lights Dataset [50] είναι ένα ευρύ σύνολο δεδομένων που προορίζεται για την ανίχνευση φωτεινών σηματοδοτών, ένα κρίσιμο βήμα προς την πλήρως αυτοματοποιημένη οδήγηση σε αστικά περιβάλλοντα. Αποτελείται από 13.427 εικόνες κάμερας



Σχήμα 3.4: Επισημασμένες εικόνες οδήγησης από το BDD100K

με ανάλυση 1280x720 πιξελς και περιλαμβάνει περίπου 24.000 επισημασμένους φωτεινούς σηματοδότες. Οι επισημάνσεις περιλαμβάνουν τόσο τα οριοθετημένα πλαίσια των φωτεινών σηματοδοτών καθώς και την τρέχουσα κατάσταση (ενεργό φως) κάθε φωτεινού σηματοδότη.



Σχήμα 3.5: Επισημασμένες εικόνες οδήγησης από το Bosch

Google Open Images


Το Google Open Images Dataset [51] είναι ένα εκτενές σύνολο δεδομένων υπολογιστικής όρασης που περιλαμβάνει περίπου 9 εκατομμύρια εικόνες με ετικέτες που καλύπτουν χιλιάδες κατηγορίες αντικειμένων

Lisa Traffic Lights


Το LISA Traffic Light Dataset είναι ένα εκτενές σύνολο δεδομένων που αναπτύχθηκε για την υποστήριξη της έρευνας στην ανίχνευση και αναγνώριση φωτεινών σηματοδοτών, κρίσιμο στοιχείο για τα συστήματα αυτόνομης οδήγησης. Αυτό το σύνολο δεδομένων περιλαμβάνει βίντεο και σχολιασμένα καρέ που περιέχουν φωτεινούς σηματοδότες στις Ηνωμένες Πολιτείες, με ποικιλία σεναρίων οδήγησης, όπως διαφορετικές ώρες της ημέρας και συνθήκες φωτισμού.

Traffic Light Detection Dataset

Το Traffic Light Detection Dataset είναι ένα σύνολο δεδομένων φωτεινών σηματοδοτών που έχει αναρτηθεί στην ιστοσελίδα *Roboflow Universe*. Περιέχει 4000 εικόνες με επισημάνσεις για τρεις κατηγορίες φωτεινών σηματοδοτών (Traffic-Green, Traffic-Red, Traffic-Yellow).



Σχήμα 3.6: Επισημασμένες εικόνες του συνούβλου δεδομένων Google Open Images



Σχήμα 3.7: Παράδειγμα εικόνας με φωτεινούς σηματοδότες από το Lisa Traffic Lights dataset

Αυτό το σύνολο δεδομένων είναι διαθέσιμο για λήψη και μπορεί να χρησιμοποιηθεί για την εκπαίδευση μοντέλων ανίχνευσης αντικειμένων, συμβάλλοντας στην ανάπτυξη εφαρμογών υπολογιστικής όρασης που σχετίζονται με την αναγνώριση φωτεινών σηματοδοτών.



Προετοιμασία Δεδομένων


Κατά την προεπεξεργασία των δεδομένων που χρησιμοποιήθηκαν για την εκπαίδευση του μοντέλου, συλλέχθηκαν εικόνες από έξι διαφορετικά datasets τα οποία περιείχαν εικόνες

φωτεινών σηματοδοτών. Ο σκοπός ήταν να εντοπιστούν και να απομονωθούν εικόνες που περιέχουν φωτεινούς σηματοδότες, οι οποίοι αποτελούν το κύριο αντικείμενο ενδιαφέροντος για την ανάλυση.

Δεδομένου ότι η Υπερανάλυση Εικόνας (Super-Resolution) απαιτεί εικόνες υψηλής ποιότητας κατά τη διαδικασία εκπαίδευσης, κρίθηκε απαραίτητο να φιλτραριστούν και να αποκλειστούν τα δεδομένα χαμηλής ανάλυσης. Για να διασφαλιστεί η χρησιμότητα των δεδομένων, αποφασίστηκε να διατηρηθούν μόνο οι φωτεινοί σηματοδότες των οποίων τα bounding boxes καταλαμβάνουν περιοχή μεγαλύτερη από 2500 pixels, καθώς θεωρήθηκε ότι τέτοια δεδομένα παρέχουν επαρκή πληροφορία για την εκπαίδευση του μοντέλου.

Αφού προσδιορίστηκαν οι σηματοδότες που πληρούσαν τα προαναφερθέντα κριτήρια, έγιναν cropped ώστε να δημιουργηθούν οι νέες εικόνες που προορίζονταν για εκπαίδευση του μοντέλου μας. Για να διασφαλιστεί η ομοιομορφία στις διαστάσεις και να δημιουργηθούν εικόνες συμβατές με το μοντέλο, εφαρμόστηκε padding στις cropped εικόνες, προκειμένου να παραχθούν τελικά εικόνες με διαστάσεις 256x256 pixels. Αυτή η διαδικασία όχι μόνο επέτρεψε την τυποποίηση των δεδομένων εισόδου, αλλά διασφάλισε και τη διατήρηση των κρίσιμων λεπτομερειών των φωτεινών σηματοδοτών, επιτρέποντας στο μοντέλο να εκπαιδευτεί με δεδομένα υψηλής ποιότητας και συνέπειας.

Για να παρουσιαστεί η κατανομή των εικόνων, που χρησιμοποιήθηκαν από κάθε dataset, παρατίθεται το ακόλουθο γράφημα, το οποίο απεικονίζει τους αριθμούς των εικόνων που επιλέχθηκαν από κάθε ένα από τα έξι datasets. Το γράφημα αυτό παρέχει μια σαφή εικόνα της συμβολής κάθε dataset στη διαμόρφωση του τελικού συνόλου δεδομένων.



Συνολικά, συλλέξαμε 8.157 εικόνες φωτεινών σηματοδοτών, με διαστάσεις 256x256 pixels. Με σκοπό την αύξηση του αριθμού των εικόνων που απαρτίζουν το dataset, αποφασίσαμε να εφαρμόσουμε τεχνικές data augmentation. Δεδομένου ότι στο πλαίσιο της εργασίας για

την υπερανάλυση εικόνας η ποιότητα των εικόνων αποτελεί τον πλέον καθοριστικό παράγοντα για την επιτυχία ή την αποτυχία του μοντέλου, κρίναμε ότι τεχνικές επαύξησης όπως η προσθήκη θορύβου, η προσαρμογή των χρωμάτων ή το MixUp δεν ήταν κατάλληλες. Επιπλέον, λόγω του περιορισμού που επιβάλλεται από τις σταθερές διαστάσεις των εικόνων (256x256 pixels), αποκλείστηκαν τεχνικές που θα μπορούσαν να τροποποιήσουν τις διαστάσεις τους. Ως εκ τούτου, επιλέξαμε να αυξήσουμε το σύνολο των εικόνων μας μέσω τεχνικών όπως το mirroring (καθρεπτισμός) και την περιστροφή κατά $\pm 90^\circ$. Μετά την εφαρμογή αυτών των τεχνικών, το τελικό σύνολο των εικόνων αυξήθηκε σε 32.628, αριθμός που είναι πρακτικά τετραπλάσιος σε σχέση με το αρχικό.



Σχήμα 3.8: Η αυθεντική εικόνα (στα αριστερά) μαζί με τις επαυξημένες εκδοχές της: καθρεπτισμένη εικόνα (η δεύτερη) και οι περιστροφές της κατά -90 και $+90$ μοίρες αντίστοιχα

Είναι αξιοσημείωτο πως αυτό που καθιστά το πρόβλημα των φωτεινών σηματοδοτών ιδιαίτερα πολύπλοκο είναι η μεγάλη ποικιλομορφία τους. Οι φωτεινοί σηματοδότες μπορούν να διαφέρουν σε σχήμα, μορφή, χρώμα και προσανατολισμό, ενώ η εμφάνισή τους επηρεάζεται από εξωτερικούς παράγοντες όπως ο φωτισμός, η ώρα της ημέρας και οι καιρικές συνθήκες. Αυτές οι μεταβλητές καθιστούν την αναγνώριση και την υπερανάλυσή τους ένα ιδιαίτερα απαιτητικό πρόβλημα, που απαιτεί προσαρμοστικά και ισχυρά μοντέλα για την αποτελεσματική αντιμετώπισή του.

Παρακάτω παρατίθενται ορισμένα παραδείγματα φωτεινών σηματοδοτών που βρίσκονται στο σύνολο δεδομένων μας για να φανερώσουν την εγγενή πολυπλοκότητα του προβλήματος.



Σχήμα 3.9: Διαφορετική ώρα της ημέρας



Σχήμα 3.10: Διαφορετικό σχήμα φαναριού



Σχήμα 3.11: Διαφορετικό χρώμα

3.2 Υπερανάλυση με το μοντέλο SinSR

Τα πρόσφατα επιτεύγματα των μοντέλων διάχυσης έχουν ανοίξει νέους ορίζοντες στον χώρο των παραγωγικών μοντέλων, με εφαρμογές που εκτείνονται από τη σύνθεση εικόνων έως την απαλοιφή θορύβου και την ανακατασκευή. Ωστόσο, ένα από τα βασικά μειονεκτήματα των παραδοσιακών μοντέλων διάχυσης, όπως τα DDPMs (Denoising Diffusion Probabilistic Models), είναι η υπολογιστική τους αναποτελεσματικότητα, καθώς η παραγωγή μιας εικόνας υψηλής ποιότητας απαιτεί συχνά εκατοντάδες βήματα. Αυτό αποτελεί σημαντικό περιορισμό σε εφαρμογές που απαιτούν χαμηλό χρόνο απόκρισης, όπως η αυτόνομη πλοήγηση ή η ιατρική απεικόνιση.

Το SinSR (Single-Step Super-Resolution) [52] προτείνει μια καινοτόμο λύση, μειώνοντας τη διαδικασία παραγωγής σε ένα μόνο ντετερμινιστικό βήμα. Συνδυάζει την ευελιξία των μοντέλων διάχυσης με την αποδοτικότητα στη χρονική πολυπλοκότητα, χρησιμοποιώντας ένα σχήμα δύο σταδίων: ένα μοντέλο teacher (διαχτυτικό) και ένα μοντέλο student, το οποίο μαθαίνει μέσω απεσταγμένης μάθησης να αναπαράγει το αποτέλεσμα του πρώτου σε ένα μόνο πέρασμα.


3.2.1 Διατύπωση Προβλήματος

Έστω $x \in \mathbb{R}^{H \times W \times C}$ μια εικόνα χαμηλής ανάλυσης και $y \in \mathbb{R}^{sH \times sW \times C}$ η αντίστοιχη εικόνα υψηλής ανάλυσης με παράγοντα μεγέθυνσης s . Στόχος είναι η εκμάθηση μιας συνάρτησης $F : x \rightarrow y$ που θα ανακατασκευάζει τις λεπτομέρειες που χάθηκαν κατά τη διαδικασία υποδειγματοληψίας.

Η παραδοσιακή προσέγγιση μέσω μοντέλων διάχυσης στοχεύει στην προσέγγιση της κατανομής $p(y | x)$ μέσω μιας μαρκοβιανής αλυσίδας αποθρουδοποίησης. Το SinSR αντίθετα επιχειρεί να προσεγγίσει αυτή την κατανομή άμεσα, σε ένα μόνο βήμα.

3.2.2 Αρχιτεκτονική

Το SinSR βασίζεται σε αρχιτεκτονική τύπου U-Net, ενσωματώνοντας Swin Transformer blocks [53] αντί για κλασικά self-attention layers, ώστε να συλλάβει αποδοτικά τόσο τοπικά όσο και παγκόσμια συμφραζόμενα. Περιλαμβάνει έναν κωδικοποιητή, έναν αποκωδικοποιητή και skip connections μεταξύ τους.



Σχήμα 3.12: Αρχιτεκτονική SinSR: το μοντέλο μαθητής προβλέπει την High Resolution εικόνα από το διαχτυτικό μοντέλο δασκάλου με τη βοήθεια Knowledge Distillation.

3.2.3 Εκπαίδευσης

Το SinSR εκπαιδεύεται μέσω ενός teacher-student σχήματος. Ο teacher είναι ένα τυπικό DDPM που μαθαίνει να ανακατασκευάζει την εικόνα μέσα από διαδοχικά βήματα αποθορυβοποίησης. Ο student εκπαιδεύεται ώστε να προσεγγίζει το τελικό αποτέλεσμά του απευθείας από την πιο θορυβώδη αναπαράσταση:

$$x_t = \sqrt{a_t}y + \sqrt{1 - a_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

$$F_{\hat{\theta}}(x_T, x) \approx y$$

3.2.4 Συναρτήσεις Απώλειας

Για την αποδοτική μεταφορά γνώσης, χρησιμοποιούνται τρεις απώλειες:

- Distillation Loss:

$$\mathcal{L}_{distill} = \|F_{\hat{\theta}}(x_T, x) - f_{\theta}^{(0)}(x_T, x)\|_2^2$$

- Reconstruction Loss:

$$\mathcal{L}_{recon} = \|F_{\hat{\theta}}(x_T, x) - y\|_2^2$$

- Inversion Loss:

$$\mathcal{L}_{inverse} = \|f_{\hat{\theta}}(x_0, x, 0) - x_T\|_2^2$$

Η συνολική απώλεια είναι:

$$\mathcal{L}_{total} = \mathcal{L}_{distill} + \mathcal{L}_{recon} + \mathcal{L}_{inverse}$$

3.2.5 Πλεονεκτήματα του SinSR

- **Ταχύτητα Εκτέλεσης:** Ένα μόνο πέρασμα για παραγωγή εικόνας υψηλής ανάλυσης.
- **Ανθεκτικότητα σε Θόρυβο:** Κληρονομεί τις δυνατότητες αποθορυβοποίησης του teacher.
- **Ευελιξία σε Ανάλυση και Περιεχόμενο:** Οι Swin Transformers εξασφαλίζουν προσαρμοστικότητα σε διάφορα μεγέθη και σενάρια.

3.2.6 Μετρικές Αξιολόγησης

- PSNR: Ακρίβεια ανακατασκευής σε επίπεδο pixel.
- SSIM: Διαρθρωτική ομοιότητα με εικόνα αναφοράς.
- LPIPS: Αντιληπτική ομοιότητα μέσω embeddings.
- MUSIQ, CLIPQA: Μετρικές ποιότητας βασισμένες σε transformers και contrastive learning.

Οι παραπάνω μετρικές διασφαλίζουν ότι το SinSR παράγει εικόνες που είναι όχι μόνο λεπτομερείς αλλά και ρεαλιστικές σε επίπεδο αντίληψης.

3.3 Η Διάταξή μας

Στη συγκεκριμένη εργασία, η διάταξή μας συνδυάζει ένα state-of-the-art αλγόριθμο ανίχνευσης αντικειμένων με την προσέγγιση της υπερανάλυσης εικόνας που παρέχεται από το SinSR, για τη βέλτιστη επεξεργασία και βελτίωση της ανάλυσης συγκεκριμένων αντικειμένων. Η συνολική διαδικασία περιγράφεται παρακάτω.

Αρχικά, κάθε εικόνα εισόδου περνά μέσα από έναν σύγχρονο αλγόριθμο ανίχνευσης αντικειμένων, το YOLO (You Only Look Once)[1]. Το YOLO, το οποίο φημίζεται για την ταχύτητα και ακρίβειά του, εντοπίζει τα αντικείμενα ενδιαφέροντος στην εικόνα και παράγει τα αντίστοιχα bounding boxes.

Στη συνέχεια, τα αντικείμενα που εντοπίζονται, περικλείονται μέσα στα οριοθετημένα πλαίσια (bounding boxes) και εξάγονται από την αρχική εικόνα μέσω της διαδικασίας cropping. Αυτό έχει ως αποτέλεσμα τη δημιουργία εικόνων που περιέχουν αποκλειστικά τα αντικείμενα ενδιαφέροντος, επιτρέποντας την εστίαση του επόμενου σταδίου μόνο στις κρίσιμες λεπτομέρειες.

Οι εξαγόμενες εικόνες περνούν στη συνέχεια από το SinSR, το οποίο εφαρμόζει την προτεινόμενη μέθοδο διάχυσης για τη βελτίωση της ανάλυσης. Η διαδικασία αυτή διασφαλίζει ότι τα αντικείμενα ενδιαφέροντος αποδίδονται σε πολύ υψηλότερη ποιότητα, αποκαλύπτοντας επιπλέον λεπτομέρειες και πληροφορίες που ήταν προηγουμένως μη ορατές στην εικόνα χαμηλής ανάλυσης.

Η ολοκληρωμένη διάταξη ενσωματώνει τα πλεονεκτήματα της ταχείας ανίχνευσης του YOLO και της ισχυρής υπερανάλυσης εικόνας του SinSR, παρέχοντας ένα αποτελεσματικό

εργαλείο για την ενίσχυση της ποιότητας εικόνας σε εφαρμογές όπου η ανάλυση και η λεπτομέρεια έχουν πρωταρχική σημασία.



Σχήμα 3.13: Η διάταξή μας: Από την ανίχνευση αντικειμένων μέσω του YOLO στη βελτίωση της ανάλυσης μέσω του SinSR.

3.4 Μετρικές

MUSIQ - Multi-scale Image Quality Το MUSIQ είναι ένα μοντέλο αξιολόγησης ποιότητας εικόνας που χρησιμοποιεί μετασχηματιστές (transformers) για την ανάλυση χαρακτηριστικών εικόνας σε πολλαπλές κλίμακες. Η πολυκλιμακωτή προσέγγιση του MUSIQ του επιτρέπει να αξιολογεί τόσο τη συνολική δομή όσο και τις λεπτομέρειες, καθιστώντας το ιδανικό για εικόνες φυσικών τοπίων και περιεχόμενο που προβάλλεται σε διαφορετικές συσκευές.

CLIPQA – Contrastive Language–Image Pretraining Image Quality Assessment Το CLIPQA είναι μια μέθοδος που βασίζεται σε μεγάλης κλίμακας προεκπαίδευση, συνδυάζοντας γλωσσικά και οπτικά χαρακτηριστικά για την πρόβλεψη της ποιότητας μιας εικόνας. Μέσω της χρήσης σύγχρονων προεκπαιδευμένων μοντέλων, καταφέρνει να αποτυπώσει αντιληπτικές και σημασιολογικές διαφορές, καθιστώντας το κατάλληλο για εικόνες με πλούσιο περιεχόμενο και καλλιτεχνικές εφαρμογές.

3.5 Αποτελέσματα

Σε αυτήν την ενότητα παρουσιάζονται τα πειραματικά αποτελέσματα του συστήματός μας για υπερανάλυση εικόνας, με σύγκριση της απόδοσης δύο διαφορετικών διαμορφώσεων: α) YOLO σε συνδυασμό με το βασικό (vanilla) SinSR και β) YOLO σε συνδυασμό με το βελτιστοποιημένο (fine-tuned) SinSR. Η σύγκριση πραγματοποιείται σε δύο διαφορετικούς τομείς — την ιατρική απεικόνιση και την ανίχνευση αντικειμένων σε πραγματικές συνθήκες — που αντιπροσωπεύονται από τα σύνολα δεδομένων BraTS2023 και Custom Traffic Light Dataset, αντίστοιχα.

Για κάθε σύνολο δεδομένων, αξιολογούμε την απόδοση των μοντέλων τόσο μέσω ποσοτικών μετρικών (MUSIQ και CLIPQA), όσο και μέσω οπτικών συγκρίσεων. Αυτή η διττή προσέγγισή μας επιτρέπει να αξιολογήσουμε πόσο αποτελεσματικά κάθε εκδοχή του pipeline διατηρεί τις λεπτομέρειες, ενισχύει τον ρεαλισμό των εικόνων και προσαρμόζεται στις απαιτήσεις κάθε εφαρμοστικού πεδίου.

Τα πειράματα πραγματοποιήθηκαν στο περιβάλλον του Google Colab με την χρήση της T4 GPU αξιοποιώντας την βιβλιοθήκη Pytorch. Όλος ο κώδικας υλοποιήθηκε σε Python 3, διασφαλίζοντας την αναπαραγωγικότητα των αποτελεσμάτων.

BraTS2023 Dataset

Η πρώτη προσέγγιση αφορά το BraTS2023, ένα σύνολο δεδομένων ιατρικής απεικόνισης, που χρησιμοποιήθηκε για την αξιολόγηση του μοντέλου μας σε ιατρικά περιβάλλοντα υψηλής ακρίβειας.

Η εκπαίδευση πραγματοποιήθηκε για 30 εποχές, με batch size 64 και αρχικό ρυθμό εκμάθησης (learning rate) 5.0×10^{-5} σύμφωνα με το πρόγραμμα ρυθμού εκμάθησης του μοντέλου μας. Αποφασίστηκε να κάνουμε validation, ώστε να εξετάζουμε την ποιότητα της εκπαίδευσης μας, ανά 5 εποχές. Το μοντέλο μας αποθήκευε τα βάρη του ανά μία εποχή. Το σύνολο δεδομένων περιείχε 22320 MRI εγκεφάλων με κακοήθεις όγκους, και επιλέχθηκε με σκοπό την αποκατάσταση υψηλής ανάλυσης εικόνων όγκων εγκεφάλου από χαμηλής ανάλυσης εισόδους.

Το μοντέλο που βασίζεται στη βασική μέθοδο (vanilla SinSR) πέτυχε cliqa 0.46336 και musiq 43.33183. Αντίθετα, το finetuned μοντέλο που κάναμε βελτίωσε σημαντικά τα αποτελέσματα, επιτυγχάνοντας cliqa 0.51584 και musiq 44.37971. Αυτά τα αποτελέσματα δείχνουν ότι η προτεινόμενη προσέγγιση αποδίδει καλύτερα στη διατήρηση κρίσιμων λεπτομερειών και στην ακρίβεια των εικόνων.

Μέθοδος	CLIPQA	MUSIQ	Εποχές Εκπαίδευσης	Σχόλια
Vanilla SinSR	0.46336	43.33183	-	-
Finetuned model	0.51584	44.37971	30	Σημαντική βελτίωση


Πίνακας 3.2: Συνοπτικός Πίνακας Αποτελεσμάτων για την εκπαίδευση του μοντέλου μας με το BraTS2023

Τα δεδομένα του BraTS2023, λόγω της υψηλής τους δομής και ποικιλομορφίας, επέτρεψαν στο μοντέλο να γενικεύσει επιτυχώς, παρουσιάζοντας σημαντικές βελτιώσεις με τη μέθοδό μας.

Στην προσπάθεια να αξιολογήσουμε την αποτελεσματικότητα της προτεινόμενης μεθόδου, παραθέτουμε εικόνες που έχουν υποστεί επεξεργασία τόσο από τη βασική μέθοδο vanilla SinSR όσο και από τη δική μας προτεινόμενη προσέγγιση. Οι εικόνες αυτές παρουσιάζουν εμφανείς διαφορές στην ποιότητα και την ευκρίνεια. Η vanilla SinSR μέθοδος διατηρεί τις βασικές λεπτομέρειες, αλλά συχνά αποτυγχάνει να αναδείξει τις πιο λεπτομερείς πληροφορίες στις εικόνες χαμηλής ανάλυσης. Αντίθετα, η δική μας μέθοδος προσφέρει σημαντικά βελτιωμένη απόδοση, αποκαλύπτοντας περισσότερες λεπτομέρειες και ενισχύοντας τη συνολική ποιότητα της εικόνας. Η σύγκριση αυτή καταδεικνύει τη δύναμη της προτεινόμενης προσέγγισης, ειδικά σε περιπτώσεις όπου η ανάλυση και η λεπτομέρεια παίζουν κρίσιμο ρόλο.

Τα αποτελέσματα αυτής της σύγκρισης παρουσιάζονται στα Σχήματα 3.14, 3.15, 3.16, και 3.17, όπου παρουσιάζονται δίπλα-δίπλα τα αποτελέσματα από το vanilla SinSR και από το fine-tuned μοντέλο. Οι αντίστοιχες ποσοτικές αξιολογήσεις, συμπεριλαμβανομένων των


μετρικών CLIPQA και MUSIQ, παρέχονται στους πίνακες 3.3, 3.4, 3.5 και 3.6.



Σχήμα 3.14: Σύγκριση μαγνητικής τομογραφίας ενός πρώτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου

	CLIPQA	MUSIQ
Vanilla SinSR	0.58877	31.01172
Finetuned SinSR	0.67096	35.09375


Πίνακας 3.3: Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον πρώτο ασθενή



Σχήμα 3.15: Σύγκριση μαγνητικής τομογραφίας ενός δεύτερου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου

	CLIPiQA	MUSIQ
Vanilla SinSR	0.52724	26.76562
Finetuned SinSR	0.65398	33.679695


Πίνακας 3.4: Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον δεύτερο ασθενή



Σχήμα 3.16: Σύγκριση μαγνητικής τομογραφίας ενός τρίτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου

	CLIPQA	MUSIQ
Vanilla SinSR	0.57583	31.16667
Finetuned SinSR	0.66020	36.26562

Πίνακας 3.5: Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον τρίτο ασθενή



Σχήμα 3.17: Σύγκριση μαγνητικής τομογραφίας ενός τέταρτου ασθενούς μεταξύ του vanilla SinSR μοντέλου και του fine-tuned μοντέλου

	CLIPQA	MUSIQ
Vanilla SinSR	0.58643	31.01172
Finetuned SinSR	0.67096	35.09375

Πίνακας 3.6: Ποσοτική αξιολόγηση των αποτελεσμάτων των μαγνητικών τομογραφιών για τον τέταρτο ασθενή

Custom Traffic Light Dataset

Στη δεύτερη προσέγγιση, το μοντέλο εκπαιδεύτηκε στο Custom Dataset Φωτεινών Σηματοδοτών, στο οποίο προαναφερθήκαμε λεπτομερώς, και επιλέχθηκε για να αξιολογηθεί η απόδοση του μοντέλου σε δεδομένα που αντικατοπτρίζουν ρεαλιστικά σενάρια.

Η εκπαίδευση πραγματοποιήθηκε σε 20 εποχές, χρησιμοποιώντας τις ίδιες παραμέτρους εκπαίδευσης με το προηγούμενο dataset. Οι εικόνες περιελάμβαναν διαφορετικούς φωτεινούς σηματοδότες από διάφορα μέρη του πλανήτη, ληφθείσες σε διάφορες γωνίες και συνθήκες φωτισμού, καθ'όλη τη διάρκεια της ημέρας.

Μέθοδος	CLIPQA	MUSIQ	Εποχές Εκπαίδευσης	Σχόλια
Vanilla SinSR	0.619685	61.859375	-	-
Finetuned model	0.620766	57.435679	20	Μέτρια απόδοση λόγω ποιότητας dataset


Πίνακας 3.7: Συνοπτικός Πίνακας Αποτελεσμάτων για την εκπαίδευση του μοντέλου μας με το Traffic Light Dataset

Στη βασική μέθοδο (vanilla SinSR), οι τιμές CLIPQA και MUSIQ ήταν 0.619685 και 61.859375, αντίστοιχα. Το fine tuned μοντέλο δεν παρουσίασε κάποια αξιοσημείωτη βελτίωση, με CLIPQA 0.620766 και MUSIQ 57.435679, γεγονός που οφείλεται στην πολυπλοκότητα των αντικειμένων που θέλουμε να εφαρμόσουμε υπερ-ανάλυση, όπως έχουμε αναφέρει.

Τα αποτελέσματα υποδεικνύουν ότι το dataset στο οποίο εκπαιδεύσαμε το μοντέλο μας, πιθανόν να μην περιείχε επαρκή ποικιλομορφία ή ποιότητα για να υποστηρίξει την εκπαίδευση του μοντέλου. Αυτό φανερώνει την ανάγκη για περαιτέρω εμπλουτισμό του dataset ή χρήση πιο ισχυρών τεχνικών προεπεξεργασίας.

Στην περίπτωση των εικόνων των φωτεινών σηματοδοτών, παραθέτουμε αποτελέσματα από την επεξεργασία τόσο με τη βασική μέθοδο vanilla SinSR όσο και με τη δική μας προτεινόμενη προσέγγιση. Στις συγκεκριμένες εικόνες, δεν παρατηρείται κάποια σημαντική διαφορά στην ποιότητα και την ευκρίνεια ανάμεσα στις δύο μεθόδους. Και οι δύο προσεγγίσεις αποτυγχάνουν να αναδείξουν επιπλέον λεπτομέρειες, πιθανώς λόγω της φύσης του dataset, που δεν παρέχει επαρκή ποικιλομορφία ή λεπτομέρειες για περαιτέρω βελτιώσεις. Η σύγκριση αυτή υπογραμμίζει την ανάγκη για εμπλουτισμό του dataset ή τη χρήση πιο εξειδικευμένων τεχνικών για δεδομένα όπως αυτά.


Τα αποτελέσματα αυτής της σύγκρισης παρουσιάζονται στα σχήματα 3.18 και 3.19, όπου παρουσιάζουμε δίπλα-δίπλα τις εξόδους του vanilla SinSR και του μοντέλου που εκπαιδεύσαμε σε εικόνες φωτεινών σηματοδοτών. Οι αντίστοιχες ποσοτικές αξιολογήσεις, συμπεριλαμβανομένων των μετρικών CLIPQA και MUSIQ, παρέχονται στους πίνακες 3.8 και 3.9. Αυτές οι συγκρίσεις δείχνουν ότι και τα δύο μοντέλα αποδίδουν παρόμοια αποτελέσματα, αναδεικνύοντας τους περιορισμούς του συνόλου δεδομένων που χρησιμοποιήθηκε.



Σχήμα 3.18: Σύγκριση των αποτελεσμάτων υπερ-ανάληψης για τον πρώτο φωτεινό σηματοδότη μεταξύ του βασικού μοντέλου SinSR και του fine-tuned μοντέλου

	CLIPQA	MUSIQ
Vanilla SinSR	0.63090	59.68750
Finetuned SinSR	0.65129	61.31250

Πίνακας 3.8: Ποσοτική αξιολόγηση των αποτελεσμάτων



Σχήμα 3.19: Σύγκριση των αποτελεσμάτων υπερ-ανάληψης για τον δεύτερο φωτεινό σηματοδότη μεταξύ του βασικού μοντέλου SinSR και του fine-tuned μοντέλου

	CLIPQA	MUSIQ
Vanilla SinSR	0.60847	64.03125
Finetuned SinSR	0.59024	69.25000

Πίνακας 3.9: Ποσοτική αξιολόγηση των αποτελεσμάτων

Επίλογος

4.1 Συμπεράσματα

Ανακεφαλαιώνοντας, στην παρούσα διπλωματική εργασία, εξετάσαμε την εφαρμογή της τεχνικής της υπερανάλυσης εικόνας μέσω του state of the art μοντέλου Single Step Super Resolution (SinSR) σε δύο διαφορετικά datasets: το BraTS2023 και ένα custom dataset φωτεινών σηματοδοτών, το οποίο αποτελείται από ένα σύνολο φωτεινών σηματοδοτών που έχουν εξαχθεί από διαφορετικά σύνολα δεδομένων. Με βάση την πειραματική μας ανάλυση προέκυψε ότι, για το dataset BraTS2023, το μοντέλο μας κατάφερε να εκπαιδευτεί επιτυχώς, παρουσιάζοντας θετικά αποτελέσματα στην αναβάθμιση της ανάλυσης εικόνων. Ωστόσο, τα αποτελέσματα για το custom dataset φωτεινών σηματοδοτών δεν ήταν το ίδιο ενθαρρυντικά, καθώς δεν παρατηρήθηκε ουσιαστική πρόοδος στην υπερανάλυση αυτών των εικόνων.

Η επιτυχία στην εκπαίδευση του SinSR στο BraTS2023 αποδεικνύει ότι το συγκεκριμένο μοντέλο μπορεί να αποδώσει αποτελεσματικά σε δεδομένα ιατρικής απεικόνισης υψηλής ποιότητας. Η δυσκολία που παρατηρήθηκε στο custom dataset φωτεινών σηματοδοτών αναδεικνύει πιθανές προκλήσεις που σχετίζονται με τη φύση των δεδομένων, όπως η χαμηλή ποικιλομορφία, η ποιότητα ή η έλλειψη αντιπροσωπευτικών χαρακτηριστικών που απαιτούνται για την αποτελεσματική γενίκευση του μοντέλου.

4.2 Μελλοντικές Επεκτάσεις

Η παρούσα εργασία ανοίγει το δρόμο για περαιτέρω έρευνα και βελτιώσεις στην εφαρμογή της υπερανάλυσης εικόνας. Συγκεκριμένα, οι μελλοντικές επεκτάσεις περιλαμβάνουν:

- **Αύξηση της ποικιλομορφίας και ποιότητας του dataset φωτεινών σηματοδοτών:** Εμπλουτίζοντας το dataset με περισσότερες εικόνες από διαφορετικές συνθήκες φωτισμού, γωνίες λήψης και περιβάλλοντα, ενδέχεται να βελτιωθεί η ικανότητα του μοντέλου να αναλύει αυτά τα δεδομένα.
- **Χρήση διαφορετικών αρχιτεκτονικών SinSR μοντέλων:** Η αξιολόγηση πιο προηγμένων μοντέλων υπερανάλυσης εικόνας, όπως ESRGAN [54] ή EDSR [55], θα μπορούσε να αποκαλύψει εάν πιο ισχυρές αρχιτεκτονικές μπορούν να αντιμετωπίσουν τις προκλήσεις του custom dataset.

- **Μεταφορά μάθησης:** Η αξιοποίηση προεκπαιδευμένων μοντέλων SinSR σε μεγάλα σύνολα δεδομένων παρόμοιας φύσης θα μπορούσε να βοηθήσει στην προσαρμογή τους για την επίλυση συγκεκριμένων προβλημάτων.
- **Εξερεύνηση διαφορετικών συναρτήσεων απώλειας:** Η ενσωμάτωση εναλλακτικών συναρτήσεων κόστους, όπως *perceptual loss* ή *adversarial loss*, μπορεί να οδηγήσει σε πιο ρεαλιστικά αποτελέσματα υπερανάλυσης.
- **Αξιολόγηση σε επιπλέον datasets:** Η εφαρμογή του SinSR σε περισσότερα και ποικιλόμορφα σύνολα δεδομένων θα συμβάλλει στην εξαγωγή καθολικών συμπερασμάτων σχετικά με την αποτελεσματικότητα του μοντέλου σε διαφορετικά πεδία εφαρμογής.

Συνολικά, η εργασία αυτή επιβεβαιώνει τη δυναμική της υπερανάλυσης εικόνας σε συγκεκριμένα πεδία, ενώ ταυτόχρονα αναδεικνύει περιοχές που χρήζουν περαιτέρω διερεύνησης, θέτοντας τις βάσεις για μελλοντικές βελτιώσεις και επεκτάσεις.

Part

English Version

Chapter 5

Introduction

5.1 Motivation

Super-resolution has emerged as a novel and impactful field in computer vision, enabling the enhancement of low-resolution images to higher resolutions. This technology has many practical applications across various domains, including medicine, autonomous driving, security, and remote sensing. In medical imaging, particularly in the enhancement of brain magnetic resonance imaging, high-resolution imaging can contribute to early detection of diseases and improve diagnostic accuracy. Beyond the medical field, similar improvements in image clarity can also play a vital role in autonomous driving, where systems depend on sharp, detailed visuals to navigate safely, detect obstacles, and make split-second decisions in complex environments.

Despite the success of traditional convolutional neural networks (CNNs) and deep learning-based super-resolution approaches, existing methods often suffer from limitations such as blurriness, loss of fine details, and the introduction of unwanted artifacts. Additionally, many conventional models struggle to generalize effectively across diverse real-world datasets. This necessitates the exploration of more robust and generalizable approaches, particularly those leveraging generative models.

Recently, diffusion models have gained significant attention in the machine learning community due to their exceptional capabilities in image generation, denoising, and inpainting. Originally designed for generative tasks, these models have demonstrated their strong potential for high-quality image reconstruction, paving the way for new research directions in image super-resolution. Unlike traditional deep learning approaches, diffusion-based methods progressively refine image details through a series of learned transformations, making them particularly well-suited for reconstructing high-resolution images from their low-resolution counterparts.

Given the increasing importance of high-fidelity image reconstruction in real-world applications, this research investigates the potential of diffusion models to provide a more effective and scalable solution for super-resolution tasks. By leveraging the power of these models, we aim to explore their strengths, benchmark their performance, and bridge existing research gaps in super-resolution techniques. The findings from this study could have far-reaching implications for multiple domains, enhancing the quality and usability of super-resolution technology in critical applications.

5.2 Scope of work

This diploma thesis represents the first stage of a broader research initiative focused on exploring the dynamics of diffusion models across various applications. While the current study specifically investigates image super-resolution in domains such as [medical imaging](#) and [automated driving systems](#), diffusion models have shown great promise in a wide range of machine learning tasks, including denoising, anomaly detection, video frame interpolation, and data synthesis. Future research will expand upon the findings presented in this work, applying diffusion-based techniques to other critical areas such as satellite remote sensing and security, and time-series forecasting. By analyzing the adaptability and performance of diffusion models in different contexts, this research aims to contribute to a comprehensive understanding of their capabilities and limitations. The insights gained from this study will serve as a foundation for further exploration, bridging the gap between theoretical advancements and practical implementations in real-world applications.

5.3 Structure

This thesis is organized into five chapters, guiding the reader from foundational concepts to practical implementation and evaluation.

Chapter 5 introduces the motivation and scope of the research. It presents the core objectives of the study and outlines the structure of the thesis.

Chapter 6 provides the theoretical background necessary to understand the problem space. It explains the fundamental principles of image super-resolution and object detection, and explores key machine learning models such as Convolutional Neural Networks (CNNs). Particular emphasis is placed on diffusion models, which form the core of the proposed methodology. Building upon this foundation, the chapter expands into an overview of generative modeling approaches that have been applied to the super-resolution task. These include Autoregressive Models [56], Variational Autoencoders (VAEs) [57], Normalizing Flows (NFs) [58], and Generative Adversarial Networks (GANs) [13]. This review highlights the motivations for adopting diffusion-based models in our study.

Chapter 7 presents the methodology of the proposed system. It describes the datasets used—BraTS2023 for medical imaging and a custom Traffic Light dataset for real-world visual scenarios—as well as the data preparation process. The chapter then details the SinSR model architecture, the training strategy, and the integration of object detection (YOLO) with the super-resolution pipeline.

Chapter 8 focuses on the evaluation of the proposed pipeline. It provides both quantitative and qualitative comparisons between the baseline (vanilla) SinSR and the fine-tuned version, in the context of both medical and real-world datasets. The analysis is based on perceptual metrics such as MUSIQ and CLIPQA, offering insights into the strengths and limitations of the approach.

Finally, Chapter 9 concludes the thesis by summarizing the main findings and contributions. It also identifies current limitations and proposes directions for future research,

particularly in improving generalization, dataset diversity, and model scalability.

Chapter 6

Theoretical Background

This chapter outlines the theoretical foundations supporting the proposed image super-resolution pipeline. It begins with an overview of super-resolution techniques and object detection frameworks, which are essential for identifying regions of interest before enhancement.

We then cover core deep learning architectures—such as CNNs, U-Net, and Vision Transformers, with a focus on the Swin Transformer used in SinSR. Knowledge Distillation is also introduced as a strategy for efficient model deployment.

The chapter further reviews generative models relevant to super-resolution, including Autoregressive Models, VAEs, Normalizing Flows, and GANs. Finally, it presents Diffusion Models as a cutting-edge approach for high-fidelity image synthesis, setting the stage for the methodology and experiments that follow. standing the methodology and experimental framework presented in the following sections.

6.1 Image Super Resolution

Image super-resolution is a computer vision method that aims to improve the resolution of an image and is achieved by reconstructing a high-resolution image from a low-resolution one. This technique is vital for recovering details lost due to sensor resolution limitations or external factors and is used in a wide range of applications. These include satellite and aerial imaging [3], medical image processing [4],[5],[6], infrared imaging [7], facial image enhancement [8], vehicle plate recognition [9], fingerprint identification [10], and many other industrial and security applications.

Improving image quality can be achieved through hardware or software adaptations. Hardware-based methods, although more efficient in some cases, are often more expensive and less flexible. In contrast, software-based methods [11] are more cost effective and have the potential to be applied to existing images or systems, making them ideal for many use cases. For this reason, software-based methods have dominated scientific research and practical applications of super-resolution.

It is important to note that image super-resolution does not simply refer to the enlargement of the image dimensions, but to the increase in the number of pixels per unit area of the image. Unlike simple enlargement techniques, such as bicubic interpolation [59], which stretch the image by adding pixels through interpolation, super-resolution



Figure 6.1: Comparison of a low-resolution satellite image of the city of Paris (left) with the corresponding high resolution image (right), highlighting the enhanced sharpness and detail achieved through image processing techniques.

increases the actual pixel density, reconstructing new details that were not present in the original image. This allows for the creation of images that contain more details and higher resolution. A visual comparison of these techniques is presented in Figure 6.2, highlighting the difference in output quality between bicubic interpolation and super-resolution.




Figure 6.2: Comparison between original image, bicubic upscaling, and super-resolution. Super-resolution reconstructs realistic high-frequency details rather than simply enlarging existing pixels.

In recent years, the field has advanced rapidly, driven by the development of novel deep learning architectures such as Convolutional Neural Networks (CNNs) [12] and Generative Adversarial Networks (GANs) [13]. These methods allow for the reconstruction of details with high accuracy while preserving the naturalness and quality of the image. Despite a significant number of challenges, such as preserving existing features and avoiding artificial distortions, super-resolution continues to be one of the most promising areas of computer vision. In this paper, we will consider the application of diffusion models [14] in this area.

6.2 Object Detection

Object detection [15] is a fundamental computer vision technique that involves identifying and locating specific objects (e.g., people, buildings, cars) within digital images and videos. It combines object localization—determining an object’s position—and object classification—assigning a category label—making it a crucial tool for understanding visual content in both static and dynamic scenes.

This technique plays a central role in a wide range of applications, including autonomous driving, surveillance, robotics, and smart cities. Object detection can be implemented on still images or real-time video streams, where high-speed and accurate detection is especially valuable in time-sensitive environments.

The development of Convolutional Neural Networks (CNNs) has significantly advanced the field, leading to the creation of highly accurate and efficient object detection frameworks. Prominent models such as Faster R-CNN [16], YOLO (You Only Look Once) [1], and SSD (Single Shot MultiBox Detector) [17] have set new benchmarks in both speed and precision, balancing performance and computational efficiency.




Figure 6.3: Object detection on an urban street, with vehicle, bicycle, pedestrian and traffic light detection via numbered frames. [1]

More recently, transformer-based architectures [18] have revolutionized object detection by eliminating the need for hand-crafted region proposal mechanisms. These models utilize a global attention mechanism to model complex dependencies across an image, improving performance on tasks involving cluttered scenes or small object instances.

Despite rapid progress, object detection still faces key challenges, including occlusion, scale variation, and real-time performance constraints. Detecting tiny or overlapping objects remains difficult for many traditional models, and the computational demand of state-of-the-art systems can limit their deployment in resource-constrained environ-

ments.

Nonetheless, object detection continues to evolve rapidly, driving innovation across numerous scientific and industrial domains.

6.3 Convolutional Neural Networks

Convolutional Neural Networks (CNNs) [12] are a specialized class of deep learning models designed for processing structured grid-like data, such as images and videos. Inspired by the visual processing mechanisms of the human brain, CNNs use hierarchical layers to automatically learn spatial hierarchies of features from raw input data. Unlike traditional fully connected neural networks, CNNs leverage convolutional layers, pooling layers, and fully connected layers to capture local and global patterns efficiently.




Figure 6.4: Indicative neural network architecture.

One of the foundational components of CNNs is the convolution operation, which lies at the heart of their ability to extract features from raw data. This operation applies a filter (or kernel) to an input image to extract meaningful features. Mathematically, for a given input image $I(x, y)$ and a convolution kernel $K(a, b)$, the convolution is defined as:

$$S(x, y) = \sum_a \sum_b I(x - a, y - b) K(a, b) \quad (6.1)$$

where $S(x, y)$ is the output feature map after applying the convolution, $I(x, y)$ represents the input image, and $K(a, b)$ is the convolution kernel, a small matrix of trainable weights. The summations iterate over the dimensions of the kernel.

Early layers in a CNN typically detect low-level features such as edges, textures, or simple shapes, while deeper layers capture more abstract representations like object parts or class-specific patterns.

After the convolutional layers, CNNs often apply pooling layers to reduce the dimensionality of the feature maps while preserving the most important information. The most commonly used pooling technique is Max Pooling, defined as:

$$P(x, y) = \max_{i,j \in R} S(x + i, y + j)$$

where R is the pooling region (e.g., a 2×2 window). Max pooling retains the most significant features while reducing computational cost and overfitting.

Once high-level features are extracted through multiple convolutional and pooling layers, the final stage involves fully connected layers (FC layers). The feature maps are flattened into a one-dimensional vector and processed through a standard feedforward neural network for classification. The final prediction is obtained using softmax activation:

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

CNNs have significantly advanced the field of computer vision, enabling breakthroughs in image classification, object detection, facial recognition, and medical image analysis. Key architectures such as AlexNet [19], VGGNet [20], ResNet [21], and Inception networks [22] have pushed the boundaries of performance and efficiency in visual recognition tasks. These architectures vary in depth, computational complexity, and optimization strategies, yet they all rely on the fundamental principle of hierarchical feature extraction through convolutional operations.

One of the key advantages of CNNs is their ability to automatically learn feature representations, eliminating the need for manual feature engineering. The introduction of transfer learning has further enhanced their usability, allowing pre-trained models to be fine-tuned for specific tasks with limited labeled data. Additionally, the integration of attention mechanisms and transformer-based hybrid models has led to further improvements, enabling more robust generalization across diverse datasets.

While CNNs have driven substantial progress, they are not without challenges. Issues such as computational complexity, sensitivity to adversarial attacks, and the requirement for large labeled datasets continue to pose obstacles to their scalability and deployment in resource-constrained environments. To address these limitations, researchers are actively exploring solutions including self-supervised learning, efficient model compression, and neural architecture search.

Despite these challenges, CNNs continue to play a central role in deep learning research and applications. They remain foundational in domains such as autonomous driving, healthcare, and surveillance, among others. As innovations in artificial intelligence progress, CNNs are evolving alongside newer paradigms like Vision Transformers (ViTs) and graph-based neural networks, helping to shape the future of computer vision and intelligent systems.

6.4 U-Net

U-Net [23] is a fully convolutional neural network (FCN) specifically designed for image segmentation tasks, with widespread adoption in medical imaging. Introduced by Ronneberger et al. in 2015, U-Net has since become one of the most widely used architectures for semantic segmentation due to its ability to capture both high-level context and fine-grained spatial details through a symmetric encoder-decoder structure.

The U-Net architecture consists of two primary components:

- **Encoder (Contracting Path):** Extracts high-level features using convolution and

pooling operations.

- **Decoder (Expanding Path):** Reconstructs the segmentation map via upsampling, aided by skip connections from the encoder.

An overview of the U-Net pipeline is shown in Figure 6.5.

Encoder The encoder path consists of repeated applications of two 3×3 convolutional layers followed by ReLU activations, and then a 2×2 max pooling operation to reduce spatial resolution:

$$S_{l+1} = \max_{i,j \in R} (W_l * S_l + b_l),$$

where S_l denotes the feature map at layer l , W_l represents the convolution kernel weights, b_l is the bias term, and R is the pooling region.

The encoder captures hierarchical features, allowing the model to build abstract representations from raw input images.

Decoder The decoder path mirrors the encoder and gradually recovers spatial dimensions using upsampling layers. These layers are often implemented using transposed convolutions or nearest-neighbor interpolation followed by standard convolution:

$$U_l = \text{Upsample}(S_l),$$

where U_l denotes the upsampled feature map. Crucially, U-Net introduces skip connections that concatenate encoder features with decoder outputs at corresponding resolutions. This helps retain spatial details lost during downsampling and improves localization accuracy.

Final Output Layer A final 1×1 convolution maps the decoder's feature maps to the desired number of classes, followed by a softmax activation to produce class probabilities for each pixel:

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}},$$

where p_i is the probability of pixel i belonging to a specific class, and z_i is the network's raw output for that pixel.

U-Net has demonstrated strong performance across a broad range of domains. In medical imaging, it is applied to brain tumor segmentation [24] [25], lung nodule detection [26], and cell tracking. It is also used in satellite image analysis for road extraction [27] and land cover classification, and in autonomous driving for object segmentation and lane detection [28] [29]. Applications in agriculture and environmental monitoring include plant disease detection [30] [29] and forest change analysis [31] [32].

Despite its success, U-Net has several limitations. The model can consume significant memory due to its depth and skip connections. It may also struggle with small object

segmentation, as fine details can be lost during early pooling. Additionally, overfitting may occur on small datasets without careful regularization or data augmentation.

Various extensions of U-Net have been developed to address these issues, including U-Net++ (nested and dense skip connections) [33], Attention U-Net (learned spatial focus) [34], and 3D U-Net (volumetric data processing) [35].

In summary, U-Net remains a foundational model in image segmentation, offering a well-balanced trade-off between global context understanding and local feature preservation. Its continued evolution ensures relevance across an expanding range of applications.




Figure 6.5: U-Net architecture: a symmetric encoder-decoder structure for semantic segmentation.

6.5 Vision Transformers and Swin Transformer

While convolutional neural networks (CNNs) have long dominated computer vision tasks, recent years have seen a rapid rise in the use of transformers for image understanding. Originally developed for natural language processing, transformers rely on self-attention mechanisms that allow the model to weigh relationships between all pairs of elements in a sequence. This property has proven highly valuable for capturing long-range dependencies in visual data as well.

Vision Transformers (ViT) The Vision Transformer (ViT) [53] adapts the transformer architecture to image classification by dividing an input image into a sequence of fixed-size patches (e.g., 16×16), which are flattened and linearly embedded before being passed through a standard transformer encoder. Positional encodings are added to retain spatial information.

Despite its success in classification tasks, ViT has several limitations:

- It lacks inductive biases such as locality and translation equivariance, which are inherent to CNNs.
- It requires large-scale datasets and extensive computation to train effectively.
- Its global self-attention mechanism scales quadratically with image size, making it inefficient for high-resolution tasks.

Hierarchical Vision with Swin Transformer To address these shortcomings, Liu et al. proposed the Swin Transformer [53], a hierarchical vision transformer that computes self-attention locally within non-overlapping windows. This approach significantly reduces computational cost while preserving the ability to model long-range dependencies.

The key innovations of the Swin Transformer are:

- **Shifted Windows:** In successive layers, the window partitioning is shifted by a fixed number of pixels. This shift enables cross-window interaction without resorting to global attention, allowing the model to capture more complex spatial relationships.
- **Hierarchical Feature Maps:** Like CNNs, Swin progressively downsamples the image and increases feature dimensions, forming a multi-scale representation that supports dense prediction tasks such as object detection and super-resolution.
- **Linear Computational Complexity:** By limiting attention to fixed-size windows, the computational cost scales linearly with image size, in contrast to ViT's quadratic scaling.




Figure 6.6: (a) The proposed Swin Transformer builds hierarchical feature maps by merging image patches (shown in gray) in deeper layers and has linear computation complexity to input image size due to computation of self-attention only within each local window (shown in red). It can thus serve as a general-purpose backbone for both image classification and dense recognition tasks. (b) In contrast, previous vision Transformers [2] produce feature maps of a single low resolution and have quadratic computation complexity to input image size due to computation of self-attention globally.

Application in SinSR In the context of super-resolution, particularly in the ResShift model [60], Swin Transformers replace the traditional self-attention layers used in U-Net-based architectures. This substitution significantly improves the model’s robustness to varying image resolutions, making it more effective and scalable in real-world applications.

SinSR, the model used in this thesis, inherits this architectural modification. By incorporating Swin Transformer blocks into the U-Net backbone, SinSR benefits from efficient self-attention over large images, improved generalization across domains (e.g., medical vs natural images), and enhanced capacity for capturing both local details and global context.

Summary Vision transformers have brought a paradigm shift in computer vision, offering new ways to capture dependencies and structure in visual data. The Swin Transformer, in particular, balances performance and efficiency, making it well-suited for high-resolution tasks like super-resolution. Its integration into state-of-the-art models such as ResShift and SinSR underscores its growing importance in modern image restoration pipelines.

6.6 Knowledge Distillation

Knowledge Distillation (KD) [36] is a model compression technique designed to transfer knowledge from a large, powerful *teacher model* to a smaller, more efficient *student model*. The student is trained not only on the ground-truth labels but also on the soft outputs (probability distributions) of the teacher, which encode rich relational information between classes.

A softened softmax function is used to generate these distributions:

$$p_T(y_k | x) = \frac{\exp(z_k^T / T)}{\sum_j \exp(z_j^T / T)}, \quad (6.2)$$

where z_k^T is the logit for class k from the teacher model, and T is a temperature parameter. Higher T values yield softer probability distributions, which carry more information about inter-class similarities.

The student model minimizes the Kullback-Leibler (KL) [37] divergence between its predictions and the teacher’s softened output:

$$\mathcal{L}_{KD} = T^2 \sum_k p_T(y_k | x) \log \frac{p_T(y_k | x)}{p_S(y_k | x)}, \quad (6.3)$$

where $p_S(y_k | x)$ denotes the student model’s predicted probability. To encourage alignment with the original task, KD is often combined with cross-entropy loss on the ground truth:

$$\mathcal{L} = (1 - \lambda) \mathcal{L}_{CE} + \lambda \mathcal{L}_{KD}, \quad (6.4)$$

where λ controls the balance between ground truth supervision and distillation.

This approach enables the student model to achieve performance close to the teacher's, while being significantly lighter in terms of memory and inference cost — making KD particularly attractive for deployment on edge devices or mobile platforms.

However, KD poses several challenges. One major limitation is the potential loss of nuanced knowledge during compression, especially if the student architecture is too limited. Furthermore, optimal temperature and β selection are critical and often require empirical tuning. The pretraining of large teacher models also introduces computational overhead.

Recent developments have introduced:

- **Self-distillation:** where a model distills knowledge into itself over time.
- **Multi-teacher distillation:** which aggregates knowledge from several teachers.
- **Contrastive distillation:** using feature similarity as a supervision signal.
- **Heterogeneous distillation:** transferring knowledge across differing architectures (e.g., CNN $\rightarrow$ Transformer).

In conclusion, Knowledge Distillation remains a key strategy for model compression and efficient inference, enabling real-world deployment of high-performing models. Its ability to retain performance while reducing computational demand continues to drive its adoption across computer vision, NLP, and beyond.

6.7 Generative Modeling for Image Super-Resolution: A Historical Perspective

Before the adoption of diffusion models in image super-resolution, several other classes of generative models dominated the landscape. These include autoregressive models, variational autoencoders (VAEs), normalizing flows (NFs), and generative adversarial networks (GANs). Each of these approaches brought unique strengths to image generation tasks while also presenting specific limitations. This section briefly surveys these foundational models to highlight the progression toward more powerful generative paradigms such as diffusion models.

6.7.1 Autoregressive Models

Autoregressive models [56] constitute an important class of probabilistic models used for modeling sequential data. Their core mechanism relies on the assumption that each element in a sequence can be predicted based on its preceding elements.

In a typical autoregressive model, the probability of a variable x_t is given in terms of the previous variables in the sequence:

$$P(x_t | x_{t-1}, x_{t-2}, \dots, x_1)$$

This approach enables the model to learn long-range dependencies, making it useful in applications such as text generation, speech synthesis, and image analysis.

One of the most widely used autoregressive models in image processing is PixelCNN [61], along with its variations. These models leverage convolutional neural networks to estimate the probability distribution of each pixel, conditioning on the previously generated pixels in the image.




Figure 6.7: (Left) A visualization of PixelCNN, which maps a neighborhood of pixels to predict the next pixel. (Middle) Example of a masked 5x5 filter to prevent the model from accessing pixels below or strictly to the right of the current pixel during predictions. (Right) Two convolutional stacks (blue and purple) resolving the receptive field's blind spot.

In the field of super-resolution, although autoregressive models excel in capturing complex patterns and textures through pixel dependencies, they have certain significant limitations, such as prohibitively high computational cost and slow inference times due to the sequential nature of data generation.

6.7.2 Variational Autoencoders (VAEs)

Variational Autoencoders (VAEs) [57] are a class of latent-variable generative models that learn complex probability distributions by encoding data into a lower-dimensional latent space. Unlike autoregressive models, VAEs rely on mapping a high-dimensional structured data space into a lower-dimensional latent space, from which new data can be efficiently sampled.

A Variational Autoencoder (VAE) consists of two primary components: the encoder and the decoder. The encoder $q(z | x)$ learns to transform input data x into a probabilistic latent space representation z . The decoder $p(x | z)$ then utilizes this latent representation to reconstruct the original input data x .

The training of VAEs is based on the Variational Lower Bound [62], which maximizes the probability function of the data while minimizing the Kullback-Leibler (KL) divergence [37] between the learned latent space distribution and a predefined simple distribution (e.g., Gaussian).

Despite their efficiency in parallel sampling and reconstruction, a common drawback of VAEs is their tendency to generate overly smoothed or blurry images due to the stochastic nature of sampling from the latent space. This can significantly affect the sharpness and fine details in high-resolution applications such as super-resolution.

6.7.3 Normalizing Flows (NFs)

Normalizing Flows (NFs) [58] are a class of probabilistic models that transform a simple prior distribution into a more complex one using a sequence of invertible and differentiable transformations. Unlike other probabilistic models that rely on approximation techniques, NFs allow for precise density estimation.

Their foundation is based on the change of variables formula in probability theory. Given a random variable z with a simple distribution $p(z)$, applying an invertible transformation f results in a new variable $x = f(z)$, whose distribution is given by:

$$p(x) = p(z) \left| \det \frac{df^{-1}(x)}{dx} \right| \quad (6.5)$$

The main objective of NFs is to learn a sequence of transformations that map a simple prior distribution (e.g., Gaussian) into the target complex distribution. Training is conducted using Maximum Likelihood Estimation (MLE) [63], leveraging the exact analytical probability density function.

While NFs offer powerful and flexible density estimation, they have notable limitations. Training deep flows can be computationally expensive, and simple transformations such as Affine Coupling Layers may be restrictive, necessitating more complex variants.

6.7.4 Generative Adversarial Networks (GANs)

Generative Adversarial Networks (GANs) [13] are a class of generative models that rely on adversarial learning, where two neural networks—a generator and a discriminator—compete in a game-theoretic setting. The objective of GANs is to approximate the real data distribution, enabling the generation of realistic samples such as images, videos, and audio.

GANs consist of the generator $G(z)$ that maps a random vector z (sampled from a simple prior) into a data sample that mimics real data and the discriminator $D(x)$ that learns to distinguish real samples from generated samples.

The adversarial training process is modeled as a minimax optimization problem:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))] \quad (6.6)$$

GANs have been widely used in image generation, style transfer, and data augmentation. However, their training is often unstable, suffering from challenges such as mode collapse, where the generator produces limited variations in output.

6.7.5 Comparative Overview of Generative Models

To contextualize the advantages and limitations of different generative modeling approaches in image super-resolution, Table 6.1 provides a comparative overview of four major categories: Autoregressive Models, Variational Autoencoders (VAEs), Normalizing Flows (NFs), and Generative Adversarial Networks (GANs).




Figure 6.8: Comparison of three generative models: GANs, VAEs, and Normalizing Flows.

Table 6.1: Comparison of Generative Models for Super-Resolution Tasks

Model Type	Sampling Speed	Parallelism	Output Quality	Training Stability	Probabilistic
Autoregressive Models	Slow (sequential)	No	High	Yes	Yes
Variational Autoencoders	Fast	Yes	Moderate (blurry)	Yes	Yes
Normalizing Flows	Moderate	Yes	Moderate-High	Yes	Yes
Generative Adversarial Networks	Very Fast	Yes	High (sharp)	No	No

As seen in Table 6.1, each method offers unique benefits suited to particular tasks. Autoregressive models excel at fine-grained structure but suffer from slow generation. VAEs and NFs provide efficient training and sampling but may fall short in visual fidelity. GANs, while producing visually sharp images, often face instability during training and lack a probabilistic interpretation.

In contrast, diffusion models—introduced in the next chapter—offer a compelling blend of stability, diversity, and sample quality, making them a strong candidate for advancing image super-resolution techniques.

6.7.6 Conclusion and the Emergence of Diffusion Models

From our analysis of generative models, each approach presents distinct advantages and limitations. Given the weaknesses of these approaches, a promising alternative is the use of diffusion models, which have emerged as a strong theoretical framework with significant practical advantages.

Diffusion Models progressively refine generated images through a denoising process, leading to high-quality, diverse generative outputs. Their success in high-resolution image synthesis and super-resolution demonstrates their potential in overcoming many limitations of prior generative approaches.

6.8 Diffusion Models

Diffusion models have emerged as a powerful class of generative models, achieving state-of-the-art results in image synthesis, text-to-image generation, and data denoising. Unlike traditional generative models such as Generative Adversarial Networks (GANs) and Variational Autoencoders (VAEs), diffusion models are built upon a stochastic process that gradually transforms noise into structured data through a sequence of learned denoising steps. Recent advances in Denoising Diffusion Probabilistic Models (DDPMs) and Denoising Score Matching (DSM) have significantly improved the fidelity and controllability of generated samples, enabling a wide array of applications in domains such as image generation, audio synthesis, and beyond [38, 39, 40].

Mathematical Formulation of Diffusion Models

Diffusion models define a two-stage generative process: a forward (diffusion) process, which gradually adds noise to the data, and a reverse (denoising) process, which attempts to recover the original data from the noisy inputs.

Forward Process Given initial data $\mathbf{x}_0 \sim q(\mathbf{x})$, noise is incrementally added over T steps using a predefined variance schedule $\beta_1, \dots, \beta_T$. This results in a sequence of increasingly noisy latent variables $\mathbf{x}_1, \dots, \mathbf{x}_T$, with the forward process defined as:

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}),$$

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}),$$

where $\beta_t \in (0, 1)$ controls the rate of noise addition at each timestep.




Figure 6.9: Markov chain representation of the forward and reverse diffusion processes.

Reparameterization Trick To simplify computation, define $a_t = 1 - \beta_t$ and $\bar{a}_t = \prod_{s=1}^t a_s$. Using Gaussian noise $\epsilon_0, \dots, \epsilon_{T-1} \sim \mathcal{N}(0, \mathbf{I})$, we recursively obtain:

$$\mathbf{x}_t = \sqrt{a_t} \mathbf{x}_{t-1} + \sqrt{1 - a_t} \epsilon_{t-1} = \dots = \sqrt{\bar{a}_t} \mathbf{x}_0 + \sqrt{1 - \bar{a}_t} \epsilon_0.$$

Thus, a noisy sample at any timestep t can be directly sampled via:

$$\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{a}_t} \mathbf{x}_0, (1 - \bar{a}_t) \mathbf{I}).$$

Because β_t is a fixed hyperparameter, the values of a_t and $\bar{a}_t$ can be precomputed. This enables efficient sampling of latent variables x_t and facilitates training through a tractable loss function.

Reverse Process To generate data, the model must reverse the noising process, starting from pure Gaussian noise $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$. Ideally, one would sample from $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$, but this distribution is intractable. Instead, a parameterized neural network p_θ is trained to approximate it. The reverse process forms a Markov chain defined as:

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t),$$

where:

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{x}_T; 0, \mathbf{I}), \quad p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \sigma_\theta^2(\mathbf{x}_t, t)\mathbf{I}).$$




Figure 6.10: Illustration of the forward and reverse diffusion chains.

Diffusion models are thus latent variable models, where $\mathbf{x}_1, \dots, \mathbf{x}_T$ are latent variables used to model the data distribution $p_\theta(\mathbf{x}_0)$.

Training a Diffusion Model

Training involves maximizing the data likelihood $\log p_\theta(x_0)$, typically through the **evidence lower bound (ELBO)**:

$$\log p_{\vartheta}(x_0) \geq \mathbb{E}_{q(x_{1:T}|x_0)}[\log p_{\vartheta}(x_0|x_1)] - D_{KL}(q(x_T|x_0)||p(x_T)) - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)}[D_{KL}(q(x_{t-1}|x_t, x_0)||p_{\vartheta}(x_{t-1}|x_t))]. \quad (6.7)$$

The three terms represent:

1. A reconstruction term analogous to VAEs.
2. A KL divergence between the prior $p(x_T)$ and the noisy data.
3. A denoising loss L_t , capturing the difference between the true and learned reverse transitions.

Reparameterized Loss By conditioning on x_0 , a tractable expression for the true reverse posterior is:

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \mu_t(x_t, x_0), \tilde{\beta}_t \mathbf{I}), \quad (6.8)$$

with:

$$\tilde{\beta}_t = \frac{1 - \bar{a}_{t-1}}{1 - \bar{a}_t} \beta_t, \quad \mu_t(x_t, x_0) = \frac{\sqrt{\bar{a}_{t-1}} \beta_t}{1 - \bar{a}_t} x_0 + \frac{\sqrt{\bar{a}_t}(1 - \bar{a}_{t-1})}{1 - \bar{a}_t} x_t. \quad (6.9)$$

These coefficients depend only on the variance schedule and can be precomputed.

Neural Network Approximation and Loss Expressing x_0 in terms of noise $\epsilon \sim \mathcal{N}(0, I)$, we get:

$$x_0 = \frac{1}{\sqrt{\bar{a}_t}} (x_t - \sqrt{1 - \bar{a}_t} \epsilon). \quad (6.10)$$

The model learns to estimate the noise ϵ using a neural network $\epsilon_{\vartheta}(x_t, t)$, leading to the estimated mean:

$$\mu_{\vartheta}(x_t, t) = \frac{1}{\sqrt{\bar{a}_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{a}_t}} \epsilon_{\vartheta}(x_t, t) \right). \quad (6.11)$$

The denoising loss is then:

$$L_t = \mathbb{E}_{x_0, t, \epsilon} \left[\frac{\beta_t}{2\bar{a}_t(1 - \bar{a}_t)} \|\epsilon - \epsilon_{\vartheta}(x_t, t)\|_2^2 \right]. \quad (6.12)$$

Simplified Loss Ho et al. [14] proposed a simplified version that omits the weighting term:

$$L_t^{\text{simple}} = \mathbb{E}_{x_0, t, \epsilon} \left[\left\| \epsilon - \epsilon_{\vartheta} \left(\sqrt{\bar{a}_t} x_0 + \sqrt{1 - \bar{a}_t} \epsilon, t \right) \right\|_2^2 \right], \quad (6.13)$$

which has proven effective while improving training stability and sample quality.

Variance Learning Originally, the model learned only the mean of the reverse transitions, using fixed variance. Nichol et al. [41] later extended this by allowing the model to learn the variance Σ as well, yielding improved generative performance.

Algorithm 1 Training	Algorithm 2 Sampling
1: repeat 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 3: $t \sim \text{Uniform}(\{1, \dots, T\})$ 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 5: Take gradient descent step on $\nabla_{\theta} \ \epsilon - \epsilon_{\theta}(\sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1 - \alpha_t}\epsilon, t)\ ^2$ 6: until converged	1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 2: for $t = T, \dots, 1$ do 3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$ 4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$ 5: end for 6: return $\mathbf{x}_0$

Figure 6.11: *Training and sampling procedures in diffusion models.*

In summary, diffusion models offer a principled and stable approach to generative modeling, combining strong theoretical foundations with empirical success in high-resolution image generation. Their flexibility and robustness make them especially suitable for super-resolution tasks, which require gradual and realistic detail refinement.

Chapter 7

Methodology

This chapter presents the methodological foundation of the proposed system, encompassing the datasets, models, and the integrated processing pipeline. It begins with an overview of the two primary datasets used for image super-resolution: BraTS2023, which focuses on medical imaging, and a composite traffic light dataset, which supports visual understanding in autonomous driving contexts. The following sections describe in detail the two core models employed—SinSR for super-resolution and YOLO for real-time object detection—along with their respective architectures, and training procedures. The chapter concludes with a presentation of the complete end-to-end layout that combines detection and enhancement, highlighting how the individual components are integrated into a unified pipeline.

7.1 Data Sets

7.1.1 BraTS2023

Brain tumors are among the most lethal forms of cancer. In particular, glioblastoma and diffuse astrocytoma with molecular characteristics of glioblastoma—classified as grade 4 astrocytoma by the World Health Organization (WHO)—are the most common and aggressive primary malignant tumors of the central nervous system in adults. These tumors exhibit high levels of heterogeneity in terms of appearance, shape, and histological characteristics, with a median survival rate of only 15 months.

The diagnosis and treatment of brain tumors present significant clinical challenges, as these malignancies are inherently resistant to conventional therapies. This resistance is primarily attributed to difficulties in drug delivery across the blood-brain barrier and to the extensive inter- and intra-patient heterogeneity present at radiographic, morphological, and molecular levels. Despite these obstacles, decades of intensive research aimed at improving diagnostic precision, tumor characterization, and personalized treatment strategies have contributed to measurable reductions in brain tumor mortality rates.

In an effort to advance state-of-the-art brain tumor segmentation techniques, the annual Brain Tumor Segmentation (BraTS) Challenge has been established. It serves as a benchmark competition for the development and evaluation of automated segmentation algorithms targeting diffuse gliomas and their subregions. As part of this initiative, the

BraTS dataset is made available to the research community for training, validation, and testing purposes.

The BraTS (Brain Tumor Segmentation) dataset is widely adopted for segmentation tasks involving multimodal magnetic resonance imaging (MRI) scans. It incorporates four distinct imaging modalities:

- **T1-weighted (T1)**: Provides high-resolution anatomical details of brain structures.
- **T1 with contrast enhancement (T1c)**: Highlights disruptions in the blood-brain barrier and is effective for identifying active tumor regions.
- **T2-weighted (T2)**: Emphasizes differences in tissue composition, particularly in fluid-rich areas.
- **FLAIR (Fluid-Attenuated Inversion Recovery)**: Suppresses cerebrospinal fluid signals to improve lesion contrast and visibility.

Each modality plays a crucial role in the comprehensive identification and localization of brain tumor components. Together, they offer a robust multimodal perspective for the early detection, diagnosis, and monitoring of neurological diseases.




Figure 7.1: MRI scans of brains showing tumors of various sizes.

BraTS is particularly valued for the high quality of its annotations, which are manually curated by medical imaging experts. These annotations include pixel-level segmentation labels that delineate tumor subregions with exceptional precision. Such granularity is of critical importance, as well-annotated datasets remain scarce in medical imaging—posing a major bottleneck for the advancement of biomedical artificial intelligence (AI) systems [4]. The scarcity of labeled data, combined with variability in MRI acquisition protocols and scanner types, underlines the necessity of standardized, expert-validated datasets like BraTS.

The dataset supports a wide range of clinical and research applications, including tumor subregion segmentation, patient survival prediction, and tumor growth modeling. Accurate delineation of tumor components is essential for treatment planning and

response monitoring, while prognostic models based on imaging biomarkers assist in tailoring therapies to individual patients. Moreover, longitudinal tumor analysis across multiple time points can yield valuable insights into the evolution of tumor biology and its interaction with various treatments.

In this study, we utilize BraTS2023, the most recent edition of the dataset curated for the 2023 challenge. This version builds upon its predecessors by introducing several notable improvements: an expanded collection of patient cases, enhanced manual annotations for greater precision, and improved consistency across imaging modalities. These updates were made with the goal of enabling the development of even more robust and generalizable segmentation algorithms [47], [5], [6]. The dataset plays a critical role in advancing clinical applications, including AI-driven diagnosis, radiotherapy planning, disease monitoring, and personalized medicine initiatives in neuro-oncology.

Data Preparation

To prepare the BraTS2023 dataset for use in super-resolution model training, careful consideration was given to data structure, preprocessing consistency, and spatial standardization. The raw data were provided in the NIfTI (.nii) format, which is widely used in neuroimaging due to its ability to store three- and four-dimensional medical imaging volumes along with essential spatial metadata such as voxel resolution, dimensions, and orientation.

Data loading and preprocessing were conducted using the Nibabel Python library, which is specifically designed for manipulating NIfTI files. Each patient's scan includes four aligned MRI modalities (T1, T1c, T2, FLAIR), all of which were co-registered during acquisition. This ensured that voxel-wise anatomical alignment was preserved, allowing the models to effectively leverage multi-channel spatial features.

As the super-resolution model was trained in two-dimensional mode, the 3D volumes—originally sized at $240 \times 240 \times 155$ —were decomposed along the depth (Z) axis into a series of 2D slices. Each scan produced 155 individual axial slices per modality. Since the model input size was fixed at 256×256 pixels, zero-padding was applied to expand the original 240×240 spatial dimensions without distorting anatomical integrity. This step ensured that all inputs conformed to a uniform resolution standard, facilitating efficient batch training and improving convergence behavior.




Figure 7.2: Conversion of 3D MRI volumes into 2D axial slices at 30-slice intervals.

The resulting dataset consists of thousands of high-quality, pre-aligned slices, each preserving detailed structural and pathological information from the original MRI volumes. These slices were used as low-resolution inputs to train and evaluate the super-

resolution model, allowing for enhanced reconstruction of subtle tumor boundaries and internal heterogeneity. The preprocessing pipeline was designed to maintain anatomical fidelity while standardizing image inputs across all cases and modalities.

7.1.2 Traffic Lights

Autonomous driving represents one of the most rapidly evolving fields in artificial intelligence, with the overarching goal of developing safer, more efficient, and intelligent transportation systems. Among the key technical challenges in this domain is the real-time detection and recognition of traffic lights. These visual signals are fundamental for regulating vehicular flow, enforcing traffic rules, and minimizing the risk of collisions at intersections. Accurate detection and interpretation of traffic lights are essential for enabling autonomous vehicles to understand dynamic road conditions and interact safely with other road users.

To support the training of a robust detection system and to facilitate image super-resolution experiments in this context, a high-quality dataset of traffic light images was required. This need led to a comprehensive data collection effort, involving an extensive web-based search and curation process to identify publicly available, high-resolution traffic light datasets. Based on this effort, a custom composite dataset was compiled, aggregating relevant images from multiple sources. The dataset includes diverse real-world traffic scenes with varying environmental and contextual conditions—such as different times of day (day, night, dusk), weather patterns (sunny, overcast, rainy), and multiple traffic light shapes, colors, and configurations from different countries.

In the following sections, we describe the individual datasets that contributed to the final collection of traffic light images used in our model training pipeline. These datasets were selected based on their resolution, annotation quality, and diversity of traffic light appearances. A detailed overview of the datasets and the number of traffic light images extracted from each is shown in Table 7.1.

Table 7.1: *Traffic Light Detection Datasets and Number of Images*

Dataset	Number of Images
COCO (Common Objects in Context)	1,153
Traffic Light Detection Dataset (Roboflow)	3,210
LISA Traffic Light Dataset	944
BDD100K	1,098
Bosch Small Traffic Lights Dataset	213
Google Open Images Dataset	1,539
Total	8,157

Each of these datasets contributed unique visual perspectives and scenarios to our combined training dataset, improving its generalizability and robustness. The resulting image collection forms the basis for subsequent preprocessing and super-resolution, which are described in the next subsection.

COCO Dataset

The COCO (Common Objects in Context) dataset is a large-scale benchmark designed for object detection, segmentation, and captioning tasks. It comprises over 330,000 images, each annotated with 80 object categories and paired with five textual descriptions that provide scene-level context. COCO is widely regarded as a foundational resource in computer vision and has significantly contributed to the development and benchmarking of state-of-the-art models for detection and segmentation.




Figure 7.3: *Example images from the COCO dataset.*

BDD100K Dataset

The BDD100K dataset is one of the largest and most diverse open-source datasets for autonomous driving research. It contains 100,000 driving videos, each approximately 40 seconds in duration and recorded at a resolution of 720p and 30 frames per second. The dataset encompasses a wide range of real-world driving conditions, including various times of day, weather scenarios, and urban and rural environments. It includes annotations for several perception tasks such as object detection, drivable area segmentation, and lane marking detection, making it an excellent resource for multi-task learning in real-world driving contexts.

Bosch Small Traffic Lights Dataset

The Bosch Small Traffic Lights dataset is a specialized resource focused on the detection of small-scale traffic lights in complex driving environments. It consists of 13,427




Figure 7.4: Example of labeled driving scenes from the BDD100K dataset.

high-resolution camera images (1280×720 pixels) and includes approximately 24,000 manually annotated traffic lights. The dataset provides detailed annotations for both bounding boxes and traffic light states (e.g., red, green, yellow), making it highly valuable for training models capable of detecting small and distant traffic light instances in real time.




Figure 7.5: Example of labeled traffic light images from the Bosch dataset.

Google Open Images Dataset

The Google Open Images dataset is an extensive computer vision dataset containing approximately 9 million annotated images. It covers thousands of object categories and offers a wide range of annotation types, including image-level labels, object bounding boxes, segmentation masks, and visual relationships. For the purposes of this study, traffic light annotations were selectively extracted from this dataset to enhance the diversity and contextual richness of the training data.

LISA Traffic Light Dataset

The LISA Traffic Light dataset is tailored for research on traffic light detection and state classification, a critical component in autonomous navigation systems. It consists of annotated video sequences recorded in diverse real-world driving conditions across the United States. The dataset captures traffic lights under varying lighting conditions, times



"As we can see in the image there are few people wall, mirror and tables. On tables there are books, papers and covers."

Data Preparation

The six datasets used in this study were originally constructed for general-purpose object detection and traffic scene understanding. As such, they contained a wide range of object categories beyond traffic lights, including vehicles, pedestrians, road signs, and lane markings. To tailor the data for the specific objective of traffic light super-resolution, a targeted filtering process was applied.

First, all images containing at least one annotated traffic light were identified and extracted using the available bounding box annotations. Images that did not include traffic lights were discarded. This filtering step ensured that the resulting dataset was fully dedicated to traffic light analysis, allowing the model to focus exclusively on learning high-quality spatial representations of traffic signals.

Given that super-resolution tasks are highly sensitive to input quality, additional refinement was necessary. All identified bounding boxes were evaluated, and only those exceeding an area of 2,500 pixels were retained. This criterion was set to guarantee that each cropped region contained sufficient resolution and visual clarity for effective model training.

After filtering, each selected bounding box was used to crop the corresponding region from its original image. To ensure consistency across the dataset and compatibility with the super-resolution model, each cropped region was padded to a uniform size of 256×256 pixels. This preprocessing step preserved important spatial details while maintaining standardized input dimensions.




Figure 7.9: Distribution of selected traffic light images from each dataset after filtering.

In total, 8,157 cropped and padded traffic light images were collected. To expand the dataset and improve generalization, data augmentation techniques were employed.

However, given the importance of preserving image fidelity in super-resolution, transformations that could degrade quality—such as noise injection, color alterations, or MixUp—were excluded. Furthermore, since the model expects fixed input dimensions, augmentations that modify image size or aspect ratio were avoided.

Instead, geometric augmentations that preserve spatial integrity were used. Specifically, the dataset was expanded via horizontal mirroring and rotations of $\pm 90^\circ$, tripling the amount of training data. This augmentation strategy resulted in a final dataset of 32,628 high-resolution traffic light patches—quadrupling the size of the original post-filtered collection.



Figure 7.10: The original traffic light patch (left), mirrored version (middle left), and its -90° and $+90^\circ$ rotations.

Despite standardization and augmentation, traffic light detection remains inherently challenging due to extreme visual variability. Traffic lights differ widely in shape, form, and color depending on regional infrastructure and manufacturer design. Moreover, external environmental conditions—such as lighting, time of day, and weather—can significantly alter their appearance. These variations necessitate robust models capable of adapting to diverse real-world scenarios. To highlight the complexity of this task, the following examples illustrate the visual diversity of traffic lights.



Figure 7.11: Visual differences in traffic lights between day and night.



Figure 7.12: Examples of regional differences in traffic light design.



Figure 7.13: Variability in traffic light color and illumination across environments.

7.2 Super-Resolution with SinSR

Recent advances in diffusion models have introduced new paradigms in generative modeling, with applications ranging from image synthesis to denoising and inpainting. However, one of the key limitations of standard Denoising Diffusion Probabilistic Models (DDPMs) is their computational inefficiency: generating a single high-quality image typically requires hundreds or even thousands of iterative refinement steps. This becomes especially restrictive in time-sensitive applications such as autonomous navigation, medical imaging, or real-time video analysis.

To overcome this bottleneck, SinSR (Single-Step Super-Resolution) [52] proposes a novel formulation that reduces the generation process to a single deterministic step. SinSR combines the flexibility and robustness of diffusion models with the practicality of efficient inference. It achieves this through a two-stage pipeline: a teacher diffusion model is first used to learn a rich multi-step generative trajectory, and a student model is then distilled to replicate this process in a single forward pass.

7.2.1 Problem Formulation

Let $x \in \mathbb{R}^{H \times W \times C}$ denote a low-resolution (LR) image, and $y \in \mathbb{R}^{sH \times sW \times C}$ its corresponding high-resolution (HR) version, where s is the scaling factor. The goal of super-resolution is to learn a mapping $F : x \rightarrow y$ that reconstructs fine details lost during downsampling.

Diffusion-based approaches tackle this by modeling the conditional distribution $p(y | x)$. Traditional DDPMs approximate this distribution through a Markovian denoising process that transforms Gaussian noise into a high-resolution image via a sequence of learned transitions. In contrast, SinSR seeks to directly approximate $y \sim p(y | x)$ in a single step, thus achieving a much more tractable inference path.

7.2.2 Architecture Overview

SinSR's architecture is inspired by U-Net but replaces traditional self-attention layers with Swin Transformer blocks [53], enabling it to better handle varying input resolutions and capture long-range dependencies. The overall architecture consists of an encoder-decoder structure with skip connections, designed to process both spatial and contextual cues from the LR input.




Figure 7.14: SinSR architecture: a student network learns to predict the HR image in a single forward pass by distilling knowledge from a multi-step diffusion teacher model.

7.2.3 Training Strategy: Distillation from Diffusion

SinSR relies on a powerful teacher-student framework. The teacher is a standard DDPM trained to perform super-resolution through a sequence of denoising steps, starting from a degraded latent representation of the HR image. The student is trained to mimic the output of the teacher after its full denoising trajectory, effectively learning to "shortcut" the diffusion process.

To construct the training pairs, a degradation process is defined as:

$$x_t = \sqrt{\bar{a}_t}y + \sqrt{1 - \bar{a}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

where x_t is the noisy intermediate representation at timestep t , y is the ground truth HR image, and $\bar{a}_t$ controls the noise schedule.

The teacher model f_θ learns to denoise x_t back to y over multiple timesteps. Then, a student model $F_{\hat{\theta}}$ is trained to approximate the final output of the teacher directly from x_T , the noisiest representation:

$$F_{\hat{\theta}}(x_T, x) \approx y$$

7.2.4 Loss Functions

To ensure effective knowledge transfer and consistency, SinSR uses a combination of three loss terms:

- **Distillation Loss:** Encourages the student to match the teacher's final output.

$$\mathcal{L}_{\text{distill}} = \|F_{\hat{\theta}}(x_T, x) - f_{\hat{\theta}}^{(0)}(x_T, x)\|_2^2$$

- **Reconstruction Loss:** Aligns the student output with the ground-truth HR image.

$$\mathcal{L}_{\text{recon}} = \|F_{\hat{\theta}}(x_T, x) - y\|_2^2$$

- **Inversion Loss:** Forces reversibility by requiring the student to re-generate the

noise from its own prediction.

$$\mathcal{L}_{\text{inverse}} = \|f_{\theta}(x_0, x, 0) - x_T\|_2^2$$

The total loss used to train the student model is the unweighted sum of all three objectives:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{distill}} + \mathcal{L}_{\text{recon}} + \mathcal{L}_{\text{inverse}}$$

This ensures that the student model inherits both the fidelity and diversity of the teacher, while maintaining a strong alignment with ground truth data.

7.2.5 Advantages of SinSR

The most notable advantage of SinSR is its ability to generate perceptually high-quality HR images in a single forward pass, a dramatic improvement in speed over standard diffusion, based methods. Additionally:

- **Reduced Inference Time:** Unlike traditional diffusion models requiring hundreds of steps, SinSR is suitable for real-time applications.
- **Robustness to Noise and Artifacts:** The distilled model maintains the teacher's ability to denoise and reconstruct fine texture details.
- **Flexibility in Resolution and Context:** The use of Swin Transformers enhances adaptability to diverse resolutions and object sizes.

7.2.6 Evaluation Metrics

To quantitatively assess SinSR's performance, both pixel-wise and perceptual metrics are employed:

- **PSNR (Peak Signal-to-Noise Ratio)** – Measures reconstruction fidelity at a pixel level.
- **SSIM (Structural Similarity Index)** – Evaluates perceptual similarity based on structural coherence.
- **LPIPS (Learned Perceptual Image Patch Similarity)** – Uses deep network embeddings to gauge perceptual realism.
- **MUSIQ and CLIP-IQA** – Transformer-based and contrastive learning-based perceptual quality estimators, respectively.

Together, these metrics ensure that SinSR not only preserves fine-grained details but also delivers outputs that are visually plausible and semantically faithful.

7.3 Object Detection with YOLO

7.3.1 Introduction

YOLO (You Only Look Once) is a widely used deep learning-based object detection model designed for real-time applications. Unlike traditional object detection methods, which rely on region proposal networks or sliding windows, YOLO directly predicts bounding boxes and class probabilities in a single forward pass, making it significantly faster while maintaining high accuracy [64, 65]. This efficiency makes YOLO ideal for applications such as autonomous driving, surveillance, and robotics.



Figure 7.15: YOLO running on sample artwork and natural images

7.3.2 Model Architecture

YOLO frames object detection as a single regression problem, mapping input images to bounding boxes and class probabilities simultaneously. The architecture consists of the following key components:

Grid-Based Detection Mechanism YOLO divides the input image into an $S \times S$ grid, where each grid cell is responsible for detecting objects whose center falls within that cell. Each grid cell predicts:

- B bounding boxes, each with a confidence score.
- A class probability distribution over C object categories.

The final predictions are obtained by filtering bounding boxes based on confidence scores and applying Non-Maximum Suppression (NMS) to eliminate redundant detections.

Feature Extraction Backbone YOLO utilizes a deep convolutional network as its backbone for feature extraction. Different versions of YOLO employ different backbones: - YOLOv3/v4: Uses Darknet-53 for better accuracy-speed tradeoff. - YOLOv5: Introduces an EfficientNet-based architecture for improved efficiency. - YOLOv7: Employs advanced architectural optimizations to achieve state-of-the-art performance.

Anchor Boxes and Multi-Scale Detection Later versions of YOLO incorporate anchor boxes and multi-scale feature detection to improve performance on small and large objects. This allows the model to detect objects of varying sizes more effectively.

7.3.3 Training Process

Loss Function YOLO optimizes a multi-task loss function, which consists of three main components:

$$L_{\text{YOLO}} = L_{\text{coord}} + L_{\text{conf}} + L_{\text{class}}, \quad (7.1)$$

where:

- Localization Loss L_{coord} : Measures the error between predicted and ground-truth bounding box coordinates using Mean Squared Error (MSE):

$$L_{\text{coord}} = \hat{\lambda}_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{obj}} \left[(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2 \right]. \quad (7.2)$$

- Confidence Loss L_{conf} : Encourages accurate object confidence scores:

$$L_{\text{conf}} = \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 + \hat{\lambda}_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{I}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2. \quad (7.3)$$

- Classification Loss L_{class} : Uses cross-entropy loss to penalize misclassified objects:

$$L_{\text{class}} = \sum_{i=0}^{S^2} \mathbb{I}_i^{\text{obj}} \sum_{c \in \text{classes}} p_i(c) \log \hat{p}_i(c). \quad (7.4)$$

Optimization and Training Strategy The model is trained using:

- Batch normalization to stabilize training and improve generalization.
- Stochastic Gradient Descent (SGD) or Adam optimizer for parameter updates.
- Data augmentation techniques such as random scaling, flipping, and color jittering to enhance model robustness.

7.3.4 Inference and Object Detection Pipeline

During inference, YOLO performs object detection in a single forward pass, achieving real-time speed. The detection process follows these steps: 1. The input image is resized to a fixed dimension (e.g., 416×416 pixels). 2. The image is passed through the convolutional backbone to extract feature maps. 3. The detection head predicts bounding boxes, confidence scores, and class probabilities. 4. Thresholding and Non-Maximum Suppression (NMS) are applied to filter the final set of detections.

7.3.5 Evaluation Metrics

The model's performance is assessed using the following standard object detection metrics:

Mean Average Precision (mAP) The primary evaluation metric for YOLO is mAP, which computes the area under the Precision-Recall curve:

$$\text{mAP} = \frac{1}{C} \sum_{c=1}^C \int_0^1 P_c(R) dR, \quad (7.5)$$

where $P_c(R)$ represents precision at a given recall value for class c .

Intersection over Union (IoU) IoU measures the overlap between predicted and ground-truth bounding boxes:

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}. \quad (7.6)$$

Frame Per Second (FPS) FPS quantifies YOLO's real-time performance by measuring how many images can be processed per second.

7.3.6 Summary and Key Takeaways

YOLO provides a fast, accurate, and scalable solution for real-time object detection. By leveraging a single-shot detection approach, grid-based predictions, and an optimized multi-task loss function, YOLO achieves high accuracy with minimal computational overhead. Its versatility makes it an ideal choice for applications requiring real-time detection, including autonomous driving, security surveillance, and robotics.

7.4 Layout and Integration Pipeline

This work presents a unified pipeline that combines real-time object detection with single-step image super-resolution, leveraging the complementary strengths of YOLO and SinSR. The goal of this integration is to enhance the resolution of only the most relevant regions in an image—namely, the objects of interest—while maintaining computational efficiency and scalability.

The proposed pipeline comprises three core stages:

1. **Object Detection with YOLO:** Each input image is first passed through YOLO (You Only Look Once), a real-time object detection algorithm renowned for its speed and accuracy. YOLO detects multiple objects within the image and returns bounding boxes and class labels for each instance. This ensures precise localization of target objects without exhaustive pixel-wise analysis.
2. **Region Cropping and Isolation:** Based on the bounding box coordinates returned by YOLO, the corresponding image regions are cropped, effectively isolating the

detected objects from their surrounding context. This spatial segmentation serves two purposes: (a) it focuses computational resources exclusively on areas of interest, and (b) it facilitates cleaner super-resolution by removing irrelevant background noise.

3. **Super-Resolution via SinSR:** The cropped image patches are subsequently passed through SinSR, a single-step diffusion-based super-resolution model. SinSR enhances the spatial fidelity of these objects, recovering fine textures and structural detail that are otherwise lost in the original low-resolution input. Since SinSR operates deterministically in one forward pass, it provides high perceptual quality with minimal latency, making it suitable for deployment in real-time or near-real-time scenarios.

This modular pipeline design offers several advantages:

- **Efficiency:** By applying super-resolution only to cropped object regions instead of full images, the computational overhead is significantly reduced.
- **Scalability:** The pipeline can easily be extended to other detection models (e.g., Faster R-CNN) or super-resolution methods, allowing flexibility based on application needs.
- **Task-Specific Optimization:** Focusing resolution enhancement on objects of interest improves downstream tasks such as classification, recognition, or anomaly detection—particularly in domains like autonomous driving or medical imaging, where object clarity is critical.
- **Modularity:** Each component of the pipeline (detection, cropping, super-resolution) is decoupled and interchangeable, supporting plug-and-play experimentation and tuning.



Figure 7.16: Pipeline overview: YOLO detects objects in the input image, followed by cropping the detected region and enhancing its resolution using SinSR.

This integration allows us to selectively enhance visual information where it matters most. The layout is particularly effective in applications where both localization and clarity of small or distant objects are vital—such as medical diagnostics, satellite surveillance, and smart transportation systems. By combining precision detection with high-fidelity

upsampling, this pipeline delivers robust and interpretable image enhancement in an end-to-end fashion.

Chapter 8

Results and Evaluation

In this chapter, we evaluate the performance of the proposed pipeline by comparing two distinct configurations: YOLO combined with the baseline (vanilla) SinSR model, and YOLO integrated with our fine-tuned SinSR model. This comparison allows us to assess the contribution of the fine-tuning process to perceptual quality in both medical and real-world visual tasks.

The evaluation is carried out using the two datasets described in previous chapters—BraTS2023 for medical imaging and a custom traffic light dataset representing real-world traffic scenes. For each dataset, we present both quantitative metrics and visual comparisons to highlight the strengths and limitations of each pipeline configuration.

All experiments were conducted in the Google Colab environment, utilizing a T4 GPU and implemented using the PyTorch library. All code was written in Python 3, ensuring the reproducibility of our results.

8.1 Evaluation Metrics

The evaluation of our super-resolution models is based on two advanced perceptual image quality metrics: **MUSIQ** and **CLIPQA**. These metrics are particularly well-suited for real-world applications, as they do not require ground-truth images for comparison and focus on assessing visual fidelity and perceptual realism.

Multi-Scale Image Quality (MUSIQ) MUSIQ (Multi-Scale Image Quality) [66] is a no-reference image quality assessment (IQA) metric that estimates the perceptual quality of an image without requiring a ground-truth reference. It is particularly effective in assessing the visual fidelity of images generated by models such as those used in super-resolution, enhancement, or compression.

What sets MUSIQ apart is its multi-scale approach, which mimics how humans perceive image quality by analyzing content at various spatial resolutions. Low-resolution features help capture global structures (e.g., layout, symmetry), while high-resolution features capture local details such as edges, textures, and noise. This holistic analysis enables MUSIQ to evaluate both coarse and fine-grained artifacts.

Technically, MUSIQ employs a Vision Transformer (ViT) architecture trained on large-scale image quality datasets. The model learns to encode perceptual cues from down-

sampled versions of an input image, aggregating them to produce a final quality score. Since it does not rely on pixel-level comparisons, it is especially suited for tasks like super-resolution, where ground-truth targets may be absent or irrelevant.




Figure 8.1: *Model overview of MUSIQ*

Contrastive Language-Image Pretraining Image Quality Assessment (CLIP-IQA) CLIP-IQA [67], [68] is a modern no-reference image quality assessment (IQA) method that leverages the powerful representational capabilities of the CLIP (Contrastive Language-Image Pretraining) [69] framework. Unlike traditional metrics that rely on pixel-wise comparisons or handcrafted features, CLIP-IQA measures visual quality through the lens of semantic and perceptual alignment.

At its core, CLIP-IQA uses a pretrained CLIP model—originally designed to align images and text in a shared embedding space—to evaluate how real or plausible an image appears based on learned high-level visual features. Instead of assessing whether an image matches a ground-truth reference, CLIP-IQA evaluates whether it matches the statistical and semantic characteristics of high-quality, natural images.

This makes CLIP-IQA especially suitable for generative tasks like image super-resolution, where multiple plausible outputs can exist for a single input. In these contexts, traditional metrics such as PSNR [70] or SSIM [71] may penalize perceptually valid variations. CLIP-IQA, in contrast, focuses on semantic realism—whether an image looks like something a human would recognize as coherent and natural.

By combining deep vision-language representation learning with perceptual evaluation, CLIP-IQA provides a reliable, scalable, and human-aligned assessment of image quality. It is particularly valuable for evaluating the outputs of diffusion models, GANs, or other generative systems in the absence of paired ground truth.




Figure 8.2: Illustration of CLIPQA’s perceptual capabilities. (a) Image A demonstrates superior quality in terms of sharpness, brightness, and overall perceptual fidelity compared to Image B, as reflected in the radar chart. (b) CLIPQA’s abstract perception distinguishes semantic attributes such as “natural,” “happy,” and “aesthetic” in Image A versus “scary” and “complex” tones in Image B. These examples highlight CLIPQA’s ability to quantify both quality and abstract impressions using multimodal embeddings.

8.2 Comparative Evaluation of Our Pipeline

In this section, we present the experimental results of our super-resolution pipeline, comparing the performance of two configurations: YOLO + vanilla SinSR and YOLO + fine-tuned SinSR. The comparison is conducted across two domains—medical imaging and real-world object detection—represented by the BraTS2023 and traffic light datasets, respectively.

For each dataset, we analyze model performance through both quantitative scores (MUSIQ and CLIPQA) and visual comparisons. This dual perspective allows us to assess how well each pipeline preserves fine details, enhances image realism, and adapts to the demands of the application domain.

BraTS2023 Dataset

The first evaluation focuses on the BraTS2023 dataset, a benchmark in medical imaging designed for the segmentation and analysis of brain tumors. This dataset offers

high-resolution multimodal MRI scans, making it particularly well-suited for assessing the ability of super-resolution models to recover fine anatomical structures from low-resolution inputs.

Our model was trained for 30 epochs using a batch size of 64 and an initial learning rate of 5.0×10^{-5} , following a scheduled learning rate decay. Validation was performed every 5 epochs, with model checkpoints saved at each iteration to monitor training progress. In total, the training set included 22,320 MRI slices of glioblastoma-affected brains, providing a robust foundation for evaluating clinical-grade image reconstruction.

Quantitatively, the vanilla SinSR model achieved a CLIPIQA score of 0.46336 and a MUSIQ score of 43.33183. After fine-tuning, our model showed a substantial improvement, reaching 0.51584 in CLIPIQA and 44.37971 in MUSIQ. These results suggest that our proposed pipeline is more effective at enhancing perceptual quality and preserving medically relevant image details—critical factors in diagnostic workflows.

Method	CLIPIQA	MUSIQ	Training Epochs	Comments
Vanilla SinSR	0.46336	43.33183	-	-
Finetuned model	0.51584	44.37971	30	Significant improvement

Table 8.1: Summary Table of Results for the BraTS2023 Dataset

The structured diversity of the BraTS2023 dataset played a crucial role in enabling our model to generalize effectively across various tumor morphologies and imaging conditions. This diversity contributed to the observed improvements in both quantitative metrics and visual outcomes when using our proposed method.

To evaluate the impact of fine-tuning, we conducted a comparative analysis between outputs generated by the baseline (vanilla) SinSR model and those produced by our fine-tuned version. The differences in image sharpness, anatomical clarity, and perceptual quality are readily apparent. While the vanilla model is capable of retaining general structures, it frequently fails to reconstruct finer anatomical details. In contrast, our fine-tuned model consistently produces images with enhanced definition, improved tissue contrast, and greater structural fidelity—an essential advantage in clinical imaging scenarios where resolution is paramount.

These improvements are visually illustrated in Figures 8.3–8.6, which present side-by-side comparisons of both models across representative MRI slices. The corresponding CLIPIQA and MUSIQ scores, reported in Tables 8.2–8.5, further support the visual findings, demonstrating the effectiveness of our fine-tuned approach in enhancing both perceptual realism and diagnostic utility.




Figure 8.3: MRI comparison of a first patient between the vanilla SinSR model and the fine tuned model

	CLIPQA	MUSIQ
Vanilla SinSR	0.58877	31.01172
Finetuned SinSR	0.67096	35.09375

Table 8.2: Quantitative evaluation of MRI results for the first patient






Figure 8.4: MRI comparison of the second patient between the vanilla SinSR model and the fine tuned model

	CLIPQA	MUSIQ
Vanilla SinSR	0.52724	26.76562
Finetuned SinSR	0.65398	33.679695

Table 8.3: *Quantitative evaluation of MRI results for the second patient*Figure 8.5: *MRI comparison of the third patient between the vanilla SinSR model and the fine tuned model*

	CLIPQA	MUSIQ
Vanilla SinSR	0.57583	31.16667
Finetuned SinSR	0.66020	36.26562

Table 8.4: *Quantitative evaluation of MRI results for the third patient*Figure 8.6: *MRI comparison of the fourth patient between the vanilla SinSR model and the fine tuned model*

	CLIPQA	MUSIQ
Vanilla SinSR	0.58643	31.01172
Finetuned SinSR	0.67096	35.09375

Table 8.5: *Quantitative evaluation of MRI results for the fourth patient*

Custom Traffic Light Dataset

Following the evaluation of the BraTS2023 dataset, we turn our attention to a more challenging and visually diverse task—super-resolving traffic light imagery in real-world scenes. For this purpose, we utilized the custom traffic light dataset introduced in previous chapters, which comprises 8,157 curated images collected from publicly available datasets. These images include various viewpoints, weather conditions, and lighting scenarios, such as daytime, nighttime, and dusk.

To maintain consistency in the experimental setup, we trained the SinSR model for 20 epochs using the same training parameters as those applied to the BraTS2023 dataset. The goal of this experiment was to assess whether the fine-tuning process could improve perceptual quality in highly variable, real-world imagery where object structure is often less consistent and more occluded.

Quantitatively, the baseline SinSR model achieved a CLIPQA score of 0.619685 and a MUSIQ score of 61.859375. After fine-tuning, our model exhibited only a marginal improvement in CLIPQA (0.620766) but a notable decrease in MUSIQ (57.435679), suggesting a trade-off in perceptual sharpness versus semantic realism.

Table 8.6: *Performance Summary on Traffic Light Dataset*

Method	CLIPQA	MUSIQ	Epochs	Remarks
Vanilla SinSR	0.619685	61.859375	—	Baseline
Fine-tuned SinSR	0.620766	57.435679	20	Slight perceptual gain; reduced overall image quality

These results suggest that the dataset may lack the structural consistency and resolution required for effective learning. Unlike medical scans, which offer high anatomical regularity and well-aligned features, traffic lights appear in a broad range of configurations, often occupying only a small portion of the image. As a result, both models—vanilla and fine-tuned—struggled to extract and enhance fine visual details with consistent accuracy.

To further investigate, we visually compared outputs from both models. Figures 8.7 and 8.8 present examples where differences in visual quality are minimal. In both cases, neither model significantly outperforms the other in enhancing the sharpness or perceptual clarity of traffic light features. This limitation emphasizes the need for either a higher-resolution, better-annotated dataset or domain-specific augmentation strategies tailored to small-object enhancement.

The associated CLIPQA and MUSIQ scores for each case are listed in Tables 8.7 and 8.8, confirming the minimal performance gap between the two configurations and

underscoring the complexity of applying super-resolution to unconstrained, real-world datasets.




Figure 8.7: Comparison of super-resolution results for the first traffic light between the baseline SinSR model and the fine-tuned model

	CLIPQA	MUSIQ
Vanilla SinSR	0.63090	59.68750
Finetuned SinSR	0.65129	61.31250

Table 8.7: Quantitative evaluation of super-resolution performance for the first traffic light




Figure 8.8: Comparison of super-resolution results for the second traffic light between the baseline SinSR model and the fine-tuned model

	CLIPQA	MUSIQ
Vanilla SinSR	0.60847	64.03125
Finetuned SinSR	0.59024	69.25000

Table 8.8: Quantitative evaluation of super-resolution performance for the second traffic light

Conclusion

9.1 Conclusion

This thesis explored and analyzed the application of image super-resolution using the state-of-the-art SinSR model on two distinct datasets: BraTS2023, a high-quality medical imaging dataset, and a custom traffic light dataset composed of images extracted from various sources. Our experimental analysis demonstrated that SinSR successfully enhanced MRI images in the BraTS2023 dataset, producing promising results. However, for the custom traffic light dataset, the outcomes were less encouraging, as no significant improvements in resolution were observed.

The successful performance of SinSR on BraTS2023 suggests that the model is well-suited for structured, high-quality datasets, particularly in domains such as medical imaging, where fine details are critical. Conversely, the limited success on the traffic light dataset suggests potential constraints, likely stemming from low dataset diversity, image quality issues, or the absence of distinctive high-frequency details necessary for effective super-resolution. These findings indicate that SinSR's effectiveness is highly dependent on dataset quality, emphasizing the need for careful dataset selection and preprocessing when applying super-resolution techniques to real-world data.

The comparative analysis of both datasets provides valuable insights into the strengths and limitations of diffusion-based super-resolution methods, reinforcing the importance of data quality, diversity, and structural consistency in achieving optimal results.

9.2 Future Extensions

This study lays the groundwork for further improvements and explorations in the field of image super-resolution. To enhance SinSR's performance and applicability, future research could explore the following directions:

- **Enhancing Dataset Diversity and Quality:** Expanding the traffic light dataset with higher-quality images, captured under varied lighting conditions, perspectives, and environmental factors, could improve the model's generalization and performance.
- **Exploring Alternative Super-Resolution Architectures:** Investigating more advanced models, such as ESRGAN (Enhanced Super-Resolution GAN) or EDSR (En-

hanced Deep Super-Resolution Network), may reveal whether alternative architectures can better handle real-world, unstructured datasets.

- **Leveraging Transfer Learning:** Utilizing pre-trained SinSR models trained on large, high-resolution datasets could enhance the model's adaptability and performance on specialized domains, particularly for traffic light detection.
- **Experimenting with Different Loss Functions:** Incorporating perceptual loss (e.g., VGG-based loss) or adversarial loss (GAN-based training) could lead to more visually realistic and high-fidelity super-resolution outputs, improving the perceptual quality of generated images.
- **Evaluating Across Additional Datasets:** Expanding the analysis by applying SinSR to multiple datasets (e.g., satellite imagery, autonomous driving datasets, or industrial inspections) would provide deeper insights into its adaptability and effectiveness across diverse applications.

By addressing these future directions, the robustness and real-world applicability of SinSR can be further improved, making it a more versatile tool for various domains requiring high-resolution image reconstruction.

Bibliography

- [1] Chien Yao Wang, I Hau Yeh και Hong Yuan Mark Liao. *YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information*. 2024.
- [2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit και Neil Houlsby. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. 2020.
- [3] Eleftherios Lymperopoulos, Paraskevi Tzouveli και Stefanos Kollias. *Satellite image super-resolution for forest localization*. 2023 *International Conference on Machine Intelligence for GeoAnalytics and Remote Sensing (MIGARS)*, σελίδες 1–4. IEEE, 2023.
- [4] Nikolaos Spanos, Anastasios Arsenos, Paraskevi Antonia Theofilou, Paraskevi Tzouveli, Athanasios Voulodimos και Stefanos Kollias. *Complex Style Image Transformations for Domain Generalization in Medical Images*. 2024.
- [5] Dimitrios Pantelaios, Paraskevi Antonia Theofilou, Paraskevi Tzouveli και Stefanos Kollias. *Hybrid CNN-ViT Models for Medical Image Classification*. 2024 *IEEE International Symposium on Biomedical Imaging (ISBI)*, σελίδες 1–4. IEEE, 2024.
- [6] Natalia Salpea, Paraskevi Tzouveli και Dimitrios Kollias. *Medical Image Segmentation: A Review of Modern Architectures*. σελίδες 691–708. 2023.
- [7] Youngjun Cho, Nadia Bianchi-Berthouze, Nicolai Marquardt και Simon J Julier. *Deep Thermal Imaging: Proximate Material Type Recognition in the Wild through Deep Learning of Spatial Surface Temperature Patterns*. Τεχνική Αναφορά με αριθμό.
- [8] Iqbal Nouyed και Na Zhang. *Face Image Quality Enhancement Study for Face Recognition*. 2023.
- [9] Nouar AlDahoul, Myles Joshua Toledo Tan, Raghava Reddy Tera, Hezerul Abdul Karim, Chee How Lim, Manish Kumar Mishra και Yasir Zaki. *Advancing Vehicle Plate Recognition: Multitasking Visual Language Models with VehiclePaliGemma*. 2024.
- [10] Kai Cao και Anil K. Jain. *Automated Latent Fingerprint Recognition*. 2017.
- [11] Zhihao Wang, Jian Chen και Steven C. H. Hoi. *Deep Learning for Image Super-resolution: A Survey*. 2019.
- [12] Keiron O'Shea και Ryan Nash. *An Introduction to Convolutional Neural Networks*. 2015.

- [13] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville και Yoshua Bengio. *Generative Adversarial Networks*. 2014.
- [14] Jonathan Ho, Ajay Jain και Pieter Abbeel. *Denoising Diffusion Probabilistic Models*. 2020.
- [15] Zhong Qiu Zhao, Peng Zheng, Shou tao Xu και Xindong Wu. *Object Detection with Deep Learning: A Review*. 2018.
- [16] Shaoqing Ren, Kaiming He, Ross Girshick και Jian Sun. *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. 2015.
- [17] Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng Yang Fu και Alexander C. Berg. *SSD: Single Shot MultiBox Detector*. 2015.
- [18] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser και Illia Polosukhin. *Attention Is All You Need*. 2017.
- [19] Alex Krizhevsky, Ilya Sutskever και Geoffrey E Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. Τεχνική Αναφορά με αριθμό.
- [20] Karen Simonyan και Andrew Zisserman. *Very Deep Convolutional Networks for Large-Scale Image Recognition*. 2014.
- [21] Kaiming He, Xiangyu Zhang, Shaoqing Ren και Jian Sun. *Deep Residual Learning for Image Recognition*. 2015.
- [22] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke και Andrew Rabinovich. *Going Deeper with Convolutions*. 2014.
- [23] Olaf Ronneberger, Philipp Fischer και Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015.
- [24] Michał Futrega, Alexandre Milesi, Michal Marcinkiewicz και Pablo Ribalta. *Optimized U-Net for Brain Tumor Segmentation*. 2021.
- [25] Theophraste Henry, Alexandre Carre, Marvin Lerousseau, Theo Estienne, Charlotte Robert, Nikos Paragios και Eric Deutsch. *Brain tumor segmentation with self-ensembled, deeply-supervised 3D U-net neural networks: a BraTS 2020 challenge solution*. 2020.
- [26] Yingqi Lu, Xiangsuo Fan, Jinfeng Wang, Shaojun Chen και Jie Meng. *ParaU-Net: An improved UNet parallel coding network for lung nodule segmentation*. *Journal of King Saud University - Computer and Information Sciences*, 36, 2024.
- [27] Zhengxin Zhang, Qingjie Liu και Yunhong Wang. *Road Extraction by Deep Residual U-Net*. 2017.

- [28] Le Anh Tran και My Ha Le. *Robust U-Net-based Road Lane Markings Detection for Autonomous Driving*. 2019 International Conference on System Science and Engineering (ICSSE), σελίδες 62–66. IEEE, 2019.
- [29] Jameer Kotwal, Ramgopal Kashyap, Pathan Mohd Shafi και Vinod Kimbahune. *Enhanced leaf disease detection: UNet for segmentation and optimized EfficientNet for disease classification*. *Software Impacts*, 22:100701, 2024.
- [30] Shanwen Zhang και Chuanlei Zhang. *Modified U-Net for plant diseased leaf image segmentation*. *Computers and Electronics in Agriculture*, 204:107511, 2023.
- [31] Dmytro Filatov και Ghulam Nabi Ahmad Hassan Yar. *Forest and Water Bodies Segmentation Through Satellite Images Using U-Net*. 2022.
- [32] Kassim Kalinaki, Owais Ahmed Malik και Daphne Teck Ching Lai. *FCD-AttResU-Net: An improved forest change detection in Sentinel-2 satellite images using attention residual U-Net*. *International Journal of Applied Earth Observation and Geoinformation*, 122:103453, 2023.
- [33] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh και Jianming Liang. *UNet++: A Nested U-Net Architecture for Medical Image Segmentation*. 2018.
- [34] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y Hammerla, Bernhard Kainz, Ben Glocker και Daniel Rueckert. *Attention U-Net: Learning Where to Look for the Pancreas*. 2018.
- [35] Özgün Çiçek, Ahmed Abdulkadir, Soeren S. Lienkamp, Thomas Brox και Olaf Ronneberger. *3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation*. 2016.
- [36] Geoffrey Hinton, Oriol Vinyals και Jeff Dean. *Distilling the Knowledge in a Neural Network*. 2015.
- [37] Jonathon Shlens. *Notes on Kullback-Leibler Divergence and Likelihood*. 2014.
- [38] Ilias Mitsouras, Eleftherios Tsonis, Paraskevi Tzouveli και Athanasios Voulodimos. *U-Sketch: An Efficient Approach for Sketch to Image Diffusion Models*. 2024.
- [39] Ling Yang, Zhilong Zhang, Yang Song, Shenda Hong, Runsheng Xu, Yue Zhao, Wentao Zhang, Bin Cui και Ming Hsuan Yang. *Diffusion Models: A Comprehensive Survey of Methods and Applications*. *ACM Computing Surveys*, 56(4), 2023.
- [40] Minshuo Chen, Song Mei, Jianqing Fan και Mengdi Wang. *An Overview of Diffusion Models: Applications, Guided Generation, Statistical Rates and Optimization*. 2024.
- [41] Alex Nichol και Prafulla Dhariwal. *Improved Denoising Diffusion Probabilistic Models*. 2021.

- [42] C. Mircea S. Tesileanu, Linda Dirven, Maarten M.J. Wijnenga, Johan A.F. Koekkoek, Arnaud J.P.E. Vincent, Hendrikus J. Dubbink, Peggy N. Atmodimedjo, Johan M. Kros, Sjoerd G. Van Duinen, Marion Smits, Martin J.B. Taphoorn, Pim J. French και Martin J. Van Den Bent. *Survival of diffuse astrocytic glioma, IDH1/2 wildtype, with molecular features of glioblastoma, WHO grade IV: A confirmation of the cIMPACT-NOW criteria*. *Neuro-Oncology*, 22(4):515–523, 2020.
- [43] Anahita Fathi Kazerooni, Nastaran Khalili, Xinyang Liu, Debanjan Haldar, Zhifan Jiang, Syed Muhammed Anwar, Jake Albrecht, Maruf Adewole, Udunna Anazodo, Hannah Anderson, Sina Bagheri, Ujjwal Baid, Timothy Bergquist, Austin J. Borja, Evan Calabrese, Verena Chung, Gian Marco Conte, Farouk Dako, James Eddy, Ivan Ezhov, Ariana Familiar, Keyvan Farahani, Shuvanjan Haldar, Juan Eugenio Iglesias, Anastasia Janas, Elaine Johansen, Blaise V Jones, Florian Kofler, Dominic LaBella, Hollie Anne Lai, Koen Van Leemput, Hongwei Bran Li, Nazanin Maleki, Aaron S McAllister, Zeke Meier, Bjoern Menze, Ahmed W Moawad, Khanak K Nandolia, Julija Pavaine, Marie Piraud, Tina Poussaint, Sanjay P Prabhu, Zachary Reitman, Andres Rodriguez, Jeffrey D Rudie, Mariana Sanchez-Montano, Ibraheem Salman Shaikh, Lubdha M. Shah, Nakul Sheth, Russel Taki Shinohara, Wenxin Tu, Karthik Viswanathan, Chunhao Wang, Jeffrey B Ware, Benedikt Wiestler, Walter Wiggins, Anna Zapaishchykova, Mariam Aboian, Miriam Bornhorst, Peterde Blank, Michelle Deutsch, Maryam Fouladi, Lindsey Hoffman, Benjamin Kann, Margot Lazow, Leonie Mikael, Ali Nabavizadeh, Roger Packer, Adam Resnick, Brian Rood, Arastoo Vosough, Spyridon Bakas και Marius George Linguraru. *The Brain Tumor Segmentation (BraTS) Challenge 2023: Focus on Pediatrics (CBTN-CONNECT-DIPGR-ASNR-MICCAI BraTS-PEDs)*. 2023.
- [44] Pascal Sati, Ilena C. George, Colin D. Shea, María I. Gaitán και Daniel S. Reich. *FLAIR*: A combined MR contrast technique for visualizing white matter lesions and parenchymal veins*. *Radiology*, 265(3):926–932, 2012.
- [45] Daisuke Kawahara και Yasushi Nagata. *T1-weighted and T2-weighted MRI image synthesis with convolutional generative adversarial networks*. *Reports of Practical Oncology and Radiotherapy*, 26(1):35–42, 2021.
- [46] Wessam Mustafa, Sherif Ali, Nadia Elgendy, Samer Salama, Lamiaa El Sorogy και Mohamed Mohsen. *Role of contrast-enhanced FLAIR MRI in diagnosis of intracranial lesions*. *Egyptian Journal of Neurology, Psychiatry and Neurosurgery*, 57(1), 2021.
- [47] Georgios Sapountzakis, Paraskevi Antonia Theofilou και Paraskevi Tzouveli. *Covid-19 Detection From X-Rays Images Using Deep Learning Methods*. *2023 IEEE International Conference on Acoustics, Speech, and Signal Processing Workshops (ICASSPW)*, σελίδες 1–5. IEEE, 2023.
- [48] Tsung Yi Lin, Michael Maire, Serge Belongie, Lubomir Bourdev, Ross Girshick, James Hays, Pietro Perona, Deva Ramanan, C. Lawrence Zitnick και Piotr Dollár. *Microsoft COCO: Common Objects in Context*. 2014.

- [49] Fisher Yu, Haofeng Chen, Xin Wang, Wenqi Xian, Yingying Chen, Fangchen Liu, Vashisht Madhavan και Trevor Darrell. *BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning*. 2018.
- [50] Karim Armanious, Maurice Quach, Michael Ulrich, Timo Winterling, Johannes Friesen, Sascha Braun, Daniel Jenet, Yuri Feldman, Eitan Kosman, Philipp Rapp, Volker Fischer, Marc Sons, Lukas Kohns, Daniel Eckstein, Daniela Egbert, Simone Letsch, Corinna Voegel, Felix Huttner, Alexander Bartler, Robert Maiwald, Yancong Lin, Ulf Rüegg, Claudius Gläser, Bastian Bischoff, Jascha Freess, Karsten Haug, Kathrin Klee και Holger Caesar. *Bosch Street Dataset: A Multi-Modal Dataset with Imaging Radar for Automated Driving*. 2024.
- [51] Alina Kuznetsova, Hassan Rom, Neil Aldrin, Jasper Uijlings, Ivan Krasin, Jordi Pont-Tuset, Shahab Kamali, Stefan Popov, Matteo Mallocci, Alexander Kolesnikov, Tom Duerig και Vittorio Ferrari. *The Open Images Dataset V4: Unified image classification, object detection, and visual relationship detection at scale*. 2018.
- [52] Yufei Wang, Wenhan Yang, Xinyuan Chen, Yaohui Wang, Lanqing Guo, Lap Pui Chau, Ziwei Liu, Yu Qiao, Alex C. Kot και Bihan Wen. *SinSR: Diffusion-Based Image Super-Resolution in a Single Step*. 2023.
- [53] Ze Liu, Yutong Lin, Yuqi Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin και Baining Guo. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV, 2021.
- [54] Xintao Wang, Ke Yu, Shixiang Wu, Jinjin Gu, Yihao Liu, Chao Dong, Chen Change Loy, Yu Qiao και Xiaoou Tang. *ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks*. 2018.
- [55] Bee Lim, Sanghyun Son, Heewon Kim, Seungjun Nah και Kyoung Mu Lee. *Enhanced Deep Residual Networks for Single Image Super-Resolution*. 2017.
- [56] Murtaza Dalal, Alexander C. Li και Rohan Taori. *Autoregressive Models: What Are They Good For?* 2019.
- [57] Diederik P Kingma Google, Max Welling και Boston Delft. *An Introduction to Variational Autoencoders*. *Foundations and Trends R in Machine Learning*, xx, No. xx: 1–18, 2019.
- [58] Ivan Kobyzev, Simon J. D. Prince και Marcus A. Brubaker. *Normalizing Flows: An Introduction and Review of Current Methods*. 2019.
- [59] Donya Khaledyan, Abdollah Amirany, Kian Jafari, Mohammad Hossein Moaiyeri, Abolfazl Zargari Khuzani και Najmeh Mashhadi. *Low-Cost Implementation of Bilinear and Bicubic Image Interpolation for Real-Time Image Super-Resolution*. 2020.
- [60] Zongsheng Yue, Jianyi Wang και Chen Change Loy. *ResShift: Efficient Diffusion Model for Image Super-resolution by Residual Shifting*. 2023.

- [61] Aaron van den Oord, Nal Kalchbrenner, Oriol Vinyals, Lasse Espeholt, Alex Graves και Koray Kavukcuoglu. *Conditional Image Generation with PixelCNN Decoders*. 2016.
- [62] Yikang Gui και Prashant Doshi. *A Novel Variational Lower Bound for Inverse Reinforcement Learning*. 2023.
- [63] Yang Song, Conor Durkan, Iain Murray και Stefano Ermon. *Maximum Likelihood Training of Score-Based Diffusion Models*. 2021.
- [64] Joseph Redmon, Santosh Divvala, Ross Girshick και Ali Farhadi. *You Only Look Once: Unified, Real-Time Object Detection*. 2015.
- [65] Joseph Redmon και Ali Farhadi. *YOLOv3: An Incremental Improvement*. 2018.
- [66] Junjie Ke, Qifei Wang, Yilin Wang, Peyman Milanfar και Feng Yang. *MUSIQ: Multi-scale Image Quality Transformer*. 2021.
- [67] Xiang Zhang, Yong Shen, Xiaokang Tang, Qu Liu και Hongxin Zou. *Inverse saturable absorption mechanism and design optimization of mode-locked fiber lasers with a nonlinear amplifying loop mirror*. 2022.
- [68] Laurie Burchell, Alexandra Birch, Nikolay Bogoychev και Kenneth Heafield. *An Open Dataset and Model for Language Identification*. 2023.
- [69] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger και Ilya Sutskever. *Learning Transferable Visual Models From Natural Language Supervision*. 2021.
- [70] Fernando A. Fardo, Victor H. Conforto, Francisco C.de Oliveira και Paulo S. Rodrigues. *A Formal Evaluation of PSNR as Quality Measurement Parameter for Image Segmentation Algorithms*. 2016.
- [71] Jim Nilsson και Tomas Akenine-Möller. *Understanding SSIM*. 2020.